UNIVERSIDAD PANAMERICANA
CIUDAD UP · FACULTAD DE CIENCIAS EMPRESARIALES

Series de Tiempo para Finanzas

ARIMA · SARIMA · Pronóstico
con Datos de Commodities

Material de estudio completo
De la intuición a la aplicación en mercados de materias primas

Petróleo crudo (WTI) · Gas natural (Henry Hub) · Oro

Enero 2005 – Diciembre 2023

Verano 2026

Índice

1. Introducción **3**

2. Prerrequisitos **3**

3. Componentes principales de una serie de tiempo **3**

4. Fundamentos: estacionariedad y procesos base **4**
4.1. Estacionariedad 4
4.2. Operador de rezago y diferenciación 4
4.3. Ruido blanco 4
4.4. Procesos AR, MA y ARMA 5
4.5. Raíz unitaria e integración 5

5. ARIMA(p, d, q) **5**
5.1. Definición y fórmula general 5
5.2. Proceso de diferenciación 6
5.3. Pronóstico con ARIMA 6

6. SARIMA$(p, d, q)(P, D, Q)_s$ **6**
6.1. Motivación 6
6.2. Definición y fórmula general 7
6.3. Ejemplo: SARIMA(1,1,1)(1,1,1)$_{12}$ 7
6.4. Modelo de Airline (Box-Jenkins) 7

7. Interpretación de todos los parámetros **8**

8. ARIMA vs. SARIMA: diferencias estructurales y prácticas **9**

9. Guía para elegir p, d, q, P, D, Q **9**
9.1. Principio general 9
9.2. Cuándo diferenciar 9
9.3. Cómo ACF y PACF sugieren p y q 10
9.4. Cómo combinar ACF/PACF con AIC/BIC 10

10. Errores comunes al elegir órdenes **11**

11. ACF y PACF **11**
11.1. Definiciones formales 11
11.2. Bandas de significancia 11
11.3. Patrones clave 12

12. AIC y BIC **12**

13. Pruebas ADF y KPSS **12**
13.1. Prueba de Dickey-Fuller Aumentada (ADF) 12
13.2. Prueba KPSS 13
13.3. Cómo usarlas juntas 13

14. Transformaciones **13**

15. Parsimonia **14**

16. Box-Jenkins y diagnóstico de residuos **14**
16.1. El procedimiento de Box-Jenkins 14
16.2. Diagnóstico de residuos 15

17. Validación fuera de muestra **15**
17.1. Métricas de error predictivo 15

18. STL + ARIMA/SARIMA **16**
18.1. ¿Qué es STL? 16
18.2. Fuerza estacional 16
18.3. STL + ARIMA vs. SARIMA directo 16

19. Tabla de decisión: patrones empíricos y acciones de modelado **16**

20. Limitaciones **18**

21. Tres ejemplos con código Python **18**
21.1. Ejemplo 1: ARIMA para el precio del petróleo crudo (WTI) 18
21.2. Ejemplo 2: SARIMA para el gas natural (Henry Hub) 22
21.3. Ejemplo 3: Comparación ARIMA vs. SARIMA para el oro 26

22. Glosario de notación y conceptos **30**

23. Lista de verificación de modelado **31**

24. Síntesis final **32**

1. Introducción

Este documento es una guía de aprendizaje y repaso de examen sobre modelos ARIMA y SARIMA aplicados a series de precios de commodities. El objetivo es llevar al lector desde la intuición básica hasta la aplicación práctica con código Python real, cubriendo todos los conceptos que aparecen en un curso intermedio de series de tiempo para finanzas.

¿Por qué commodities? Los mercados de materias primas (petróleo, gas natural, metales, granos) presentan fenómenos que hacen especialmente interesante el análisis de series de tiempo: tendencias de largo plazo impulsadas por oferta y demanda global, estacionalidad climática o de consumo (por ejemplo, el gas natural se encarece en invierno), choques geopolíticos, y alta volatilidad. Modelar bien estas series tiene consecuencias económicas reales en cobertura de riesgos, planificación energética y portafolios de inversión.

Dataset. Se utiliza un archivo maestro `commodities_monthly.csv` con tres series mensuales de enero de 2005 a diciembre de 2023 (228 observaciones):

- `crude_oil_wti`: precio del petróleo crudo WTI en USD/barril
- `natural_gas_henryhub`: precio del gas natural Henry Hub en USD/MMBtu
- `gold_usd_oz`: precio del oro en USD/onza

2. Prerrequisitos

El lector debe conocer: estadística descriptiva básica (media, varianza, correlación), álgebra lineal elemental (matrices, sistemas de ecuaciones), y los fundamentos de Python (manejo de `pandas`, `numpy`, y `matplotlib`). No se requiere experiencia previa en series de tiempo.

3. Componentes principales de una serie de tiempo

Una serie de tiempo $\{Y_t\}$ es una secuencia de observaciones ordenadas en el tiempo. En la práctica, cualquier serie de precios de commodities puede descomponerse conceptualmente en cuatro componentes:

Descomposición de una serie de tiempo

$$Y_t = T_t + S_t + C_t + R_t$$

- T_t: **Tendencia** — movimiento sostenido a largo plazo. El precio del oro mostró una tendencia alcista de 2005 a 2011.
- S_t: **Estacionalidad** — patrón que se repite cada s periodos con amplitud relativamente estable. El gas natural sube en invierno.
- C_t: **Componente cíclica** — oscilaciones de largo plazo asociadas al ciclo económico (duran varios años). Menos predecible que la estacionalidad; a menudo difícil de separar de la tendencia.
- R_t: **Residuo/irregular** — variación aleatoria no explicada por los demás componentes.

Nota sobre STL. La descomposición STL (*Seasonal and Trend decomposition using Loess*) separa en la práctica *tres* componentes: $Y_t = \hat{T}_t + \hat{S}_t + \hat{R}_t$. El componente cíclico suele quedar absorbido en la tendencia estimada. STL permite que la estacionalidad

cambie gradualmente en el tiempo, lo que es imposible en la descomposición clásica. Ver Sección 18.

Modelos aditivos vs. multiplicativos.

- **Aditivo**: $Y_t = T_t + S_t + R_t$ (útil si la amplitud de la estacionalidad no crece con el nivel).
- **Multiplicativo**: $Y_t = T_t \cdot S_t \cdot R_t$, equivalente a aditivo en logaritmos: $\ln Y_t = \ln T_t + \ln S_t + \ln R_t$ (común en series de precios).

4. Fundamentos: estacionariedad y procesos base

4.1. Estacionariedad

Estacionariedad débil (de covarianza)

El proceso $\{Y_t\}_{t\in\mathbb{Z}}$ es **débilmente estacionario** si:

1. $\mathrm{E}[Y_t] = \mu$ para todo t (media constante),
2. $\mathrm{Cov}(Y_t, Y_{t-k}) = \gamma(k)$ depende sólo de k, no de t (estructura de covarianzas invariante en el tiempo).

Estacionariedad estricta

La distribución conjunta de $(Y_{t_1}, \ldots, Y_{t_m})$ coincide con la de $(Y_{t_1+h}, \ldots, Y_{t_m+h})$ para todo h y toda elección de índices. La estacionariedad estricta es más fuerte pero difícil de verificar en la práctica.

Intuición. Una serie estacionaria "tiene memoria" pero no "camina" hacia ningún lado: sus propiedades estadísticas son estables en el tiempo. Los *log-retornos* del petróleo ($r_t = \ln P_t - \ln P_{t-1}$) suelen ser estacionarios; los *log-precios* ($\ln P_t$) generalmente no lo son.

4.2. Operador de rezago y diferenciación

Operador de rezago B

$$BY_t = Y_{t-1}, \quad B^k Y_t = Y_{t-k}, \quad (1-B)Y_t = \Delta Y_t = Y_t - Y_{t-1}.$$

La diferencia estacional de orden s es $\Delta_s Y_t = (1 - B^s)Y_t = Y_t - Y_{t-s}$.

4.3. Ruido blanco

Ruido blanco $\varepsilon_t \sim WN(0$

Una secuencia $\{\varepsilon_t\}$ es ruido blanco si: $\mathrm{E}[\varepsilon_t] = 0$, $\mathrm{Var}(\varepsilon_t) = \sigma^2 < \infty$, y $\mathrm{Cov}(\varepsilon_t, \varepsilon_s) = 0$ para $t \neq s$.

El ruido blanco es el bloque constructor de todos los modelos. Si los residuos de un modelo ajustado son ruido blanco, el modelo capturó toda la estructura predecible de la serie.

4.4. Procesos AR, MA y ARMA

AR(p) — Autorregresivo

$$Y_t = \varphi_1 Y_{t-1} + \varphi_2 Y_{t-2} + \cdots + \varphi_p Y_{t-p} + \varepsilon_t = \varphi_p(B)^{-1}\Theta(B)\varepsilon_t.$$

El valor actual depende de sus p valores pasados más un error. **Condición de estacionariedad**: las raíces del polinomio $\Phi(z) = 1 - \varphi_1 z - \cdots - \varphi_p z^p$ deben estar *fuera* del círculo unitario.

MA(q) — Promedio móvil

$$Y_t = \varepsilon_t + \theta_1 \varepsilon_{t-1} + \cdots + \theta_q \varepsilon_{t-q}.$$

El valor actual es una combinación lineal de errores pasados. **Condición de invertibilidad**: las raíces de $\Theta(z) = 1 + \theta_1 z + \cdots + \theta_q z^q$ deben estar fuera del círculo unitario.

ARMA(p

$$\Phi(B)Y_t = \Theta(B)\varepsilon_t, \quad \Phi(B) = 1 - \varphi_1 B - \cdots - \varphi_p B^p, \quad \Theta(B) = 1 + \theta_1 B + \cdots + \theta_q B^q.$$

Intuición de las raíces. Si una raíz del polinomio $\Phi(z)$ está *sobre* el círculo unitario (es decir, $|z| = 1$), el proceso tiene una raíz unitaria y no es estacionario.

4.5. Raíz unitaria e integración

Proceso I(1)

Y_t es **integrado de orden 1**, denotado $I(1)$, si Y_t no es estacionario pero $\Delta Y_t = Y_t - Y_{t-1}$ sí lo es. El ejemplo canónico es la *caminata aleatoria*: $Y_t = Y_{t-1} + \varepsilon_t$. En esa caminata, $\mathrm{Var}(Y_t) = t\sigma^2 \to \infty$, por lo que no es estacionaria. Sin embargo, $\Delta Y_t = \varepsilon_t \sim WN(0, \sigma^2)$ sí lo es.

En finanzas, los *log-precios* de commodities suelen ser $I(1)$. Los *log-retornos* $r_t = \Delta \ln P_t$ son $I(0)$.

5. ARIMA(p, d, q)

5.1. Definición y fórmula general

ARIMA(p

Un proceso es **ARIMA(p, d, q)** (Autorregresivo Integrado de Promedio Móvil) si la d-ésima diferencia de Y_t sigue un ARMA(p, q):

$$\boxed{\Phi(B)\,(1-B)^d\,Y_t = \Theta(B)\,\varepsilon_t}$$

Símbolo	Significado
p	Orden autorregresivo: cuántos rezagos de Y entran al modelo
d	Grado de diferenciación ordinaria ($d = 0, 1$ o raramente 2)
q	Orden de promedio móvil: cuántos rezagos del error entran
$\Phi(B)$	Polinomio AR: $1 - \varphi_1 B - \cdots - \varphi_p B^p$
$\Theta(B)$	Polinomio MA: $1 + \theta_1 B + \cdots + \theta_q B^q$
ε_t	Ruido blanco con varianza σ^2

¿Por qué diferenciar? Si Y_t es $I(1)$, los estimadores mínimo cuadráticos ordinarios no tienen las propiedades usuales. Diferenciamos para obtener una serie $W_t = \Delta^d Y_t$ que sea estacionaria y a la que se le pueda aplicar la teoría ARMA.

5.2. Proceso de diferenciación

Para un ARIMA(1,1,1) sobre log-precios del petróleo $y_t = \ln P_t$:

$$\begin{aligned} W_t = \Delta y_t = y_t - y_{t-1} = r_t \quad &\text{(log-retorno)} \\ (1 - \varphi_1 B)\, W_t = (1 + \theta_1 B)\, \varepsilon_t \quad & \end{aligned}$$

Se obtiene un ARMA(1,1) para los log-retornos. Si $\varphi_1 = 0.15$ y $\theta_1 = -0.08$:

$$W_t = 0.15\, W_{t-1} + \varepsilon_t - 0.08\, \varepsilon_{t-1}.$$

5.3. Pronóstico con ARIMA

El pronóstico óptimo (mínimo error cuadrático medio lineal) en el horizonte h es:

$$\hat{Y}_{T+h|T} = \mathrm{E}[Y_{T+h} \mid Y_T, Y_{T-1}, \ldots]$$

Para un ARIMA(p,1,q): se predice $\Delta\hat{Y}_{T+h}$ y se acumula desde Y_T. El intervalo de predicción al 95 % es:

$$\hat{Y}_{T+h|T} \pm 1.96\, \sigma \sqrt{\sum_{j=0}^{h-1} \psi_j^2}$$

donde $\{\psi_j\}$ son los coeficientes de la representación MA(∞). La anchura del intervalo crece con h: a largo plazo, la incertidumbre se expande porque los errores se acumulan.

6. SARIMA$(p, d, q)(P, D, Q)_s$

6.1. Motivación

El ARIMA no captura estructura que se repite cada s periodos (por ejemplo, el pico de precio del gas en enero de cada año). El SARIMA extiende el ARIMA con polinomios AR y MA adicionales que operan en múltiplos del periodo s.

6.2. Definición y fórmula general

SARIMA(p

$$\boxed{\Phi_P(B^s)\,\varphi_p(B)\,(1-B^s)^D\,(1-B)^d\,Y_t = \Theta_Q(B^s)\,\theta_q(B)\,\varepsilon_t}$$

Símbolo	Significado
p, d, q	Órdenes ordinarios (igual que en ARIMA)
P	Orden AR estacional
D	Grado de diferenciación estacional
Q	Orden MA estacional
s	Periodo estacional (e.g., $s = 12$ para mensual, $s = 4$ para trimestral)
$\Phi_P(B^s)$	Polinomio AR estacional: $1 - \Phi_1 B^s - \cdots - \Phi_P B^{Ps}$
$\Theta_Q(B^s)$	Polinomio MA estacional: $1 + \Theta_1 B^s + \cdots + \Theta_Q B^{Qs}$

6.3. Ejemplo: SARIMA(1,1,1)(1,1,1)$_{12}$

Expandiendo todos los operadores:

$$(1-\Phi_1 B^{12})(1-\varphi_1 B)(1-B^{12})(1-B)\,Y_t = (1+\Theta_1 B^{12})(1+\theta_1 B)\,\varepsilon_t$$

La diferencia doble $(1-B)(1-B^{12})Y_t = Y_t - Y_{t-1} - Y_{t-12} + Y_{t-13}$ elimina tanto la tendencia ordinaria como la estacional.

6.4. Modelo de Airline (Box-Jenkins)

El modelo SARIMA(0,1,1)(0,1,1)$_{12}$ es:

$$(1-B)(1-B^{12})\,Y_t = (1+\theta_1 B)(1+\Theta_1 B^{12})\,\varepsilon_t.$$

Es uno de los modelos más parsimoniosos y exitosos para series mensuales con tendencia y estacionalidad (ventas, pasajeros aéreos, exportaciones).

7. Interpretación de todos los parámetros

Parámetro	**¿Qué controla?**	**Interpretación práctica**
φ_i (AR)	Peso de rezago i en la dinámica	Si $\varphi_1 > 0$, precios altos predicen precios altos el mes siguiente
θ_i (MA)	Peso del error pasado i	Corrige la predicción según errores recientes
d	Diferenciación ordinaria	$d = 1$: modelamos retornos; $d = 2$: modelamos cambios en retornos
Φ_i (SAR)	Efecto del mismo mes del año anterior	Si $\Phi_1 > 0$, un invierno caro predice el siguiente invierno caro
Θ_i (SMA)	Corrección MA en frecuencia estacional	Ajusta errores del mismo periodo en años anteriores
D	Diferenciación estacional	$D = 1$: elimina tendencia estacional
s	Periodo de la estacionalidad	$s = 12$ mensual, $s = 4$ trimestral, $s = 52$ semanal
σ^2	Varianza del error irreducible	Límite inferior de la incertidumbre del pronóstico

8. ARIMA vs. SARIMA: diferencias estructurales y prácticas

Dimensión	ARIMA	SARIMA
Estructura	Polinomios $\Phi(B)$ y $\Theta(B)$ ordinarios	Añade $\Phi_P(B^s)$ y $\Theta_Q(B^s)$ estacionales
Diferenciación	Solo ordinaria: $(1-B)^d$	Ordinaria *y* estacional: $(1-B)^d(1-B^s)^D$
ACF/PACF	Picos en rezagos $1,\ldots,p$ o q	Picos adicionales en $s, 2s, 3s, \ldots$
Parámetros	$p+q+1$ típicamente	$p+q+P+Q+1$ (más complejo)
Aplicación típica	Petróleo, oro, log-retornos	Gas natural, ventas, temperatura, energía
Pronóstico	No incorpora ciclos estacionales	Pronóstico captura la estación del año
Cuándo preferirlo	Serie sin patrón estacional	Serie con patrón que se repite cada s periodos

Diferencia de pronóstico. Si el gas natural siempre sube en enero, un ARIMA predicirá el mismo nivel para todos los eneros futuros, mientras que un SARIMA ajustará al alza en enero respecto a los meses previos. La diferencia práctica es significativa en decisiones de cobertura energética.

9. Guía para elegir p, d, q, P, D, Q

9.1. Principio general

Los órdenes del modelo se eligen en **cuatro etapas iterativas**: (1) identificación visual, (2) selección de candidatos con ACF/PACF, (3) estimación y comparación con AIC/BIC, (4) diagnóstico de residuos y validación fuera de muestra. No existe un algoritmo mecánico que siempre funcione; el modelado requiere criterio.

9.2. Cuándo diferenciar

- **Diferenciación ordinaria (d):** Aplica si la serie tiene tendencia estocástica (raíz unitaria). Se confirma con:
  - Gráfica: la serie "camina" sin regresar a ningún nivel.
  - ACF muestral: decae muy lentamente hacia cero.
  - Prueba ADF: no rechaza H_0 (raíz unitaria).
  - Prueba KPSS: rechaza H_0 (estacionariedad).

En la práctica, $d = 1$ suele ser suficiente para precios de commodities. **Evitar** $d = 2$ a menos que haya evidencia clara.

- **Diferenciación estacional (D):** Aplica si la ACF muestral tiene picos persistentes en los rezagos $s, 2s, 3s, \ldots$ (no decaen rápidamente). $D = 1$ es la elección más común. Combinar $D = 1$ con $d = 1$ cubre la mayoría de los casos de series mensuales con tendencia y estacionalidad.

Sobre-diferenciación

Diferenciar más de lo necesario introduce correlación negativa artificial en la ACF (pico negativo en rezago 1 de la diferenciada). Si la ACF de $\Delta^d Y_t$ muestra un pico negativo grande en el rezago 1, probablemente d es demasiado alto.

9.3. Cómo ACF y PACF sugieren p y q

Patrón en serie diferenciada	ACF	PACF
AR(p) puro	Decae (exponencial u oscilante)	Corte abrupto en rezago p
MA(q) puro	Corte abrupto en rezago q	Decae
ARMA(p, q)	Ambas decaen	Ambas decaen
Ruido blanco	≈ 0 para todo $k \geq 1$	≈ 0 para todo $k \geq 1$
AR estacional (P, lag s)	Decae en $s, 2s, \ldots$	Corte en lag Ps
MA estacional (Q, lag s)	Corte en lag Qs	Decae en $s, 2s, \ldots$

Procedimiento:

1. Graficar la serie diferenciada $W_t = \Delta^d \Delta_s^D Y_t$.
2. Trazar ACF y PACF de W_t con bandas de significancia $\pm 1.96/\sqrt{T}$.
3. Leer los cortes ordinarios (rezagos 1 a 5) para p y q.
4. Leer los cortes en múltiplos de s para P y Q.
5. Proponer 2-3 modelos candidatos.
6. Estimar y comparar AIC/BIC.
7. Elegir el modelo más parsimonioso con buenos diagnósticos de residuos.

9.4. Cómo combinar ACF/PACF con AIC/BIC

Los gráficos dan candidatos; AIC y BIC los priorizan:

- Si ACF/PACF no son concluyentes (ambas decaen), probar modelos con $p \in \{0, 1, 2\}$ y $q \in \{0, 1, 2\}$ y elegir el de menor AIC.
- Si AIC y BIC difieren, preferir BIC (más parsimonioso) salvo que el modelo con menor AIC tenga claramente mejores residuos.
- Nunca elegir un modelo sólo por AIC/BIC si los residuos muestran autocorrelación.

10. Errores comunes al elegir órdenes

Errores comunes al elegir órdenes

1. **ACF/PACF solos no son suficientes.** Con series finitas, los gráficos son ruidosos. Un pico apenas fuera de la banda puede ser ruido. Siempre confirmar con AIC/BIC y diagnóstico de residuos.

2. **AIC/BIC más bajo no siempre es el mejor.** Diferencias de AIC menores a 2 son irrelevantes; preferir el modelo más parsimonioso entre los empatados. Un modelo con AIC muy bajo pero residuos autocorrelacionados es deficiente.

3. **La sobre-diferenciación es perjudicial.** Aplicar $d = 2$ cuando $d = 1$ es suficiente destruye información y produce residuos con correlación negativa artificial. Verificar siempre la gráfica de la serie diferenciada antes de diferenciar de nuevo.

4. **Los diagnósticos de residuos siempre importan.** Si la prueba de Ljung-Box rechaza independencia en los residuos, el modelo elegido es incorrecto sin importar cuánto diga AIC/BIC. Los residuos deben parecerse a ruido blanco.

5. **Los modelos parsimoniosos suelen ser preferibles.** Un ARIMA(1,1,1) que captura la dinámica principal frecuentemente pronostica mejor fuera de muestra que un ARIMA(3,1,2) que se sobre-ajusta. En mercados de commodities, los modelos complejos son más frágiles ante cambios de régimen.

11. ACF y PACF

11.1. Definiciones formales

ACF — Función de autocorrelación

$$\rho(k) = \frac{\gamma(k)}{\gamma(0)}, \quad \gamma(k) = \mathrm{Cov}(Y_t, Y_{t-k}).$$

Estima en muestra: $\hat{\rho}(k) = \hat{\gamma}(k)/\hat{\gamma}(0)$, donde $\hat{\gamma}(k) = \frac{1}{T}\sum_{t=k+1}^{T}(Y_t - \bar{Y})(Y_{t-k} - \bar{Y})$.

PACF — Función de autocorrelación parcial

$\alpha(k)$ es la correlación entre Y_t e Y_{t-k}, *eliminando* el efecto lineal de $Y_{t-1}, \ldots, Y_{t-k+1}$. Es decir:

$$\alpha(k) = \mathrm{Corr}(Y_t - \hat{Y}_t,\ Y_{t-k} - \hat{Y}_{t-k}),$$

donde $\hat{Y}_t$ es la proyección de Y_t sobre $Y_{t-1}, \ldots, Y_{t-k+1}$.

11.2. Bandas de significancia

Bajo la hipótesis nula de ruido blanco, $\hat{\rho}(k) \approx N(0, 1/T)$. La banda al 95 % es $\pm 1.96/\sqrt{T}$. Picos que superan la banda en el correlograma indican autocorrelación estadísticamente significativa.

11.3. Patrones clave

Proceso	ACF	PACF
AR(p)	Decae exponencial u oscilante	Corte en rezago p
MA(q)	Corte en rezago q	Decae
ARMA(p, q)	Decae	Decae
Ruido blanco	≈ 0	≈ 0
I(1) sin diferenciar	Decae muy lento	Primer valor ≈ 1
Estacional (SARP)	Picos en $s, 2s, \ldots, Ps$ decayendo	Corte en rezago Ps
Estacional (SMAQ)	Corte en rezago Qs	Picos en $s, 2s, \ldots$ decayendo

12. AIC y BIC

Criterios de información

Sea $\hat{L}$ la verosimilitud maximizada, k el número de parámetros estimados y n el tamaño de la muestra:

$$\text{AIC} = -2\ln\hat{L} + 2k, \qquad \text{BIC} = -2\ln\hat{L} + k\ln n.$$

Interpretación.

- Ambos penalizan la complejidad del modelo para evitar el sobre-ajuste.
- BIC penaliza más fuerte cuando $n > 7$ ($\ln n > 2$). Para muestras grandes (como 228 meses de commodities), BIC favorece modelos más parsimoniosos.
- Se comparan modelos *dentro del mismo proceso de diferenciación*: no comparar AIC de un ARIMA(1,0,0) con uno de un ARIMA(1,1,0) porque las series dependientes son distintas.
- Un menor AIC/BIC indica mejor balance entre ajuste y complejidad, pero la diferencia debe ser al menos 2-3 unidades para ser prácticamente relevante.

13. Pruebas ADF y KPSS

13.1. Prueba de Dickey-Fuller Aumentada (ADF)

ADF

Estima el modelo:

$$\Delta Y_t = \mu + \delta Y_{t-1} + \sum_{j=1}^{k} \psi_j \Delta Y_{t-j} + \varepsilon_t.$$

H_0: $\delta = 0$ (existe raíz unitaria, la serie es $I(1)$).

H_1: $\delta < 0$ (la serie es estacionaria, $I(0)$).
Si p-valor < 0.05: rechazar $H_0 \Rightarrow$ serie estacionaria.

13.2. Prueba KPSS

KPSS

H_0: la serie es estacionaria.
H_1: la serie tiene raíz unitaria.
Si p-valor < 0.05: rechazar $H_0 \Rightarrow$ serie no estacionaria.

13.3. Cómo usarlas juntas

ADF	KPSS	Conclusión
No rechaza H_0	Rechaza H_0	Fuerte evidencia de raíz unitaria. Diferenciar.
Rechaza H_0	No rechaza H_0	Fuerte evidencia de estacionariedad. No diferenciar.
No rechaza H_0	No rechaza H_0	Señales mixtas. Revisar gráfica, aumentar muestra.
Rechaza H_0	Rechaza H_0	Señales mixtas. Posible proceso de memoria larga o quiebre estructural.

Implicaciones para la diferenciación. El orden de diferenciación d se determina aplicando ADF y KPSS iterativamente: primero en niveles, luego en primeras diferencias, hasta que ambas pruebas sean consistentes con estacionariedad.

14. Transformaciones

En series de precios de commodities, la elección de la transformación afecta el tipo de modelo y la interpretación.

Transformación	Notación	Cuándo usar
Niveles	P_t	Modelado directo; útil si la varianza es estable
Log-precios	$y_t = \ln P_t$	Estabiliza la varianza, suaviza tendencia exponencial; recomendado para precios de commodities
Retornos simples	$\frac{P_t - P_{t-1}}{P_{t-1}}$	Comparaciones entre activos; sensible a outliers
Log-retornos	$r_t = \ln P_t - \ln P_{t-1}$	Aproximación a retornos simples, aditivos en el tiempo; estándar en finanzas

Regla práctica para commodities:

- Modelar $\ln P_t$ con ARIMA(p,1,q) es equivalente a modelar r_t con ARMA(p,q).
- Si la volatilidad cambia mucho (como el petróleo en 2020), el modelo ARIMA de los log-retornos seguirá siendo inadecuado sin un componente GARCH.
- Para el gas natural con estacionalidad, modelar $\ln P_t$ con SARIMA(p,1,q)(P,1,Q)$_{12}$ es una buena práctica inicial.

15. Parsimonia

Principio de parsimonia

Entre dos modelos que describen igualmente bien los datos, preferir el que tiene *menos parámetros*. En la tradición de Box-Jenkins, un ARIMA(1,1,1) con residuos aceptables es preferible a un ARIMA(3,1,2) con marginalmente mejor AIC.

¿Por qué importa la parsimonia?

- **Interpretabilidad:** Un modelo simple tiene coeficientes con significado económico claro.
- **Pronóstico:** Modelos complejos tienden a sobre-ajustarse a la muestra y a pronosticar peor fuera de ella, especialmente en presencia de quiebres estructurales (frecuentes en commodities).
- **Estimación:** Con muestras finitas, estimar muchos parámetros introduce incertidumbre innecesaria.

Parsimonia en la práctica: Si AIC elige ARIMA(2,1,1) pero ARIMA(1,1,1) tiene residuos igualmente buenos y AIC similar (ΔAIC < 2), preferir el ARIMA(1,1,1).

16. Box-Jenkins y diagnóstico de residuos

16.1. El procedimiento de Box-Jenkins

El método de Box-Jenkins (1976) es el flujo de trabajo estándar para ajustar modelos ARIMA/SARIMA. Consta de tres etapas iterativas:

1. **Identificación:**
   - Graficar Y_t, $\ln Y_t$, y la serie diferenciada.
   - Aplicar ADF y KPSS para determinar d y D.
   - Examinar ACF y PACF de la serie diferenciada para proponer p, q, P, Q.
2. **Estimación:**
   - Estimar los parámetros por máxima verosimilitud (MV) condicional.
   - Obtener AIC/BIC para cada modelo candidato.
3. **Diagnóstico:**
   - Verificar que los residuos $\hat{\varepsilon}_t$ sean ruido blanco.
   - Si no lo son, regresar a la etapa 1 y revisar los órdenes.

16.2. Diagnóstico de residuos

Un modelo bien ajustado debe producir residuos que parezcan ruido blanco. Los diagnósticos estándar son:

1. **Gráfica de residuos vs. tiempo:** Debe mostrar fluctuaciones sin tendencia ni agrupamiento. Si se observan clústeres de alta varianza, hay heterocedasticidad (considerar GARCH).

2. **Histograma y Q-Q plot:** Verifican normalidad. En commodities, los residuos suelen ser leptocúrticos (colas pesadas).

3. **ACF de los residuos:** Todos los picos deben estar dentro de las bandas $\pm 1.96/\sqrt{T}$. Un pico significativo indica que el modelo no capturó toda la dinámica.

4. **Prueba de Ljung-Box:**

$$Q = n(n+2)\sum_{k=1}^{h} \frac{\hat{\rho}_k^2}{n-k} \sim \chi^2(h-p-q) \quad \text{bajo } H_0.$$

   H_0: los residuos son ruido blanco. Si p-valor < 0.05: rechazar H_0, el modelo es inadecuado. Se usa $h = \text{mín}(10, n/5)$ rezagos.

17. Validación fuera de muestra

División entrenamiento / validación

Dividir la serie en:

- **Conjunto de entrenamiento:** observaciones 1 a T_0. Se estima el modelo aquí.
- **Conjunto de validación:** observaciones $T_0 + 1$ a T. Se evalúa la capacidad predictiva.

¿Por qué el ajuste dentro de muestra es insuficiente? Un modelo puede memorizar el ruido de la muestra de entrenamiento y pronosticar mal. El AIC/BIC corrige parcialmente esto, pero la evaluación fuera de muestra es la prueba definitiva.

17.1. Métricas de error predictivo

Sea $\hat{Y}_{t|t-1}$ el pronóstico a un paso para la observación t, y Y_t el valor real, para $t = T_0 + 1, \ldots, T$:

$$\text{RMSE} = \sqrt{\frac{1}{T-T_0}\sum_{t=T_0+1}^{T}(Y_t - \hat{Y}_{t|t-1})^2}, \quad \text{MAE} = \frac{1}{T-T_0}\sum_{t=T_0+1}^{T}|Y_t - \hat{Y}_{t|t-1}|.$$

El MAPE (error porcentual absoluto medio) puede ser inestable cuando $Y_t \approx 0$. Para commodities, RMSE y MAE son más robustos.

Uso para comparar modelos: Si el modelo A tiene mejor AIC pero mayor RMSE fuera de muestra que el modelo B, preferir B. La validación fuera de muestra tiene la última palabra en el contexto predictivo.

18. STL + ARIMA/SARIMA

18.1. ¿Qué es STL?

STL (*Seasonal and Trend decomposition using Loess*) descompone:

$$Y_t = \hat{T}_t + \hat{S}_t + \hat{R}_t$$

usando regresión local (Loess) en ventanas móviles. Sus ventajas sobre la descomposición clásica son: (1) robusto ante valores atípicos, (2) permite que la estacionalidad evolucione lentamente, (3) flexible en el ancho de ventana.

18.2. Fuerza estacional

Un indicador útil para decidir si se necesita un modelo estacional es:

$$FS = \text{máx}\left\{0,\ 1 - \frac{\text{Var}(\hat{R}_t)}{\text{Var}(\hat{S}_t + \hat{R}_t)}\right\}.$$

$FS \approx 0$: estacionalidad débil (ARIMA puede ser suficiente). $FS \approx 1$: estacionalidad dominante (usar SARIMA o STL+ARIMA).

18.3. STL + ARIMA vs. SARIMA directo

STL + ARIMA	**SARIMA directo**
Útil cuando la estacionalidad cambia en el tiempo	Asume estacionalidad fija
Más robusto ante valores atípicos	Puede distorsionarse por outliers
Permite modelar la serie desestacionalizada con ARIMA simple	Modelo en una sola ecuación
Pronóstico requiere sumar las componentes	Pronóstico directo
Preferible con series largas ($T > 5s$)	Adecuado con muestras moderadas

Para el gas natural: La estacionalidad invernal es fuerte y relativamente estable; un SARIMA directo suele funcionar bien. Si se detectan cambios en el patrón estacional (por ejemplo, por la expansión del gas de esquisto a partir de 2012), STL + ARIMA puede ser superior.

19. Tabla de decisión: patrones empíricos y acciones de modelado

Patrón observado	**Interpretación**	**Acción**
ACF decae muy lentamente (todos los picos grandes)	Serie no estacionaria (posible raíz unitaria)	Aplicar Δ (d=1); confirmar con ADF/KPSS
ACF tiene picos en $s, 2s, 3s$ persistentes	Estacionalidad no estacionaria	Aplicar Δ_s (D=1)
PACF corta en rezago p, ACF decae	Modelo AR(p)	Usar $q = 0$, p según PACF
ACF corta en rezago q, PACF decae	Modelo MA(q)	Usar $p = 0$, q según ACF
Ambas decaen sin corte abrupto	ARMA(p, q)	Probar $p, q \in \{1, 2\}$, comparar AIC/BIC
Residuos con ACF significativa en rezago k	Orden p o q mal especificado	Incrementar p o q
Residuos con ACF significativa en rezago s	Componente estacional no capturada	Añadir P o Q
Ljung-Box rechaza H_0	Residuos no son ruido blanco	Revisar modelo; incrementar orden
AIC baja, BIC baja, RMSE alto (fuera de muestra)	Sobreajuste dentro de muestra	Reducir $p + q$; usar modelo más parsimonioso
ACF de ΔY_t con pico negativo grande en rezago 1	Posible sobrediferenciación	Probar $d = 0$ con tendencia determinista
Residuos agrupados en varianza (ARCH effect)	Heterocedasticidad condicional	Extender a ARIMA-GARCH

20. Limitaciones

Limitaciones de ARIMA y SARIMA

1. **No capturan volatilidad condicional.** Los modelos ARIMA asumen σ^2 constante. En commodities, la varianza suele ser alta en periodos de crisis (COVID-19, guerra, etc.). *Extensión:* ARIMA-GARCH o ARIMA-EGARCH.

2. **No capturan heterocedasticidad.** La varianza de los errores puede cambiar en el tiempo. El residuo del ARIMA exhibirá clústeres de volatilidad visibles en la gráfica.

3. **No capturan quiebres estructurales.** Un cambio en el régimen de precios (por ejemplo, el hundimiento del petróleo en 2014-2016) invalida los parámetros estimados antes del quiebre. *Extensión:* modelos de cambio de régimen (Markov-switching).

4. **No capturan asimetría.** Las caídas de precio suelen ser más bruscas que las subidas (asimetría negativa observada en el petróleo). El ARIMA no distingue choques positivos de negativos. *Extensión:* EGARCH, GJR-GARCH.

5. **Limitaciones de ACF/PACF en muestras finitas.** Las bandas $\pm 1.96/\sqrt{T}$ son aproximadas y pueden dar falsos positivos.

6. **AIC y BIC penalizan complejidad, no garantizan buen pronóstico.** En presencia de quiebres, un modelo seleccionado por AIC puede pronosticar muy mal.

7. **Box-Jenkins asume estacionariedad tras diferenciar.** Si la serie tiene raíces unitarias múltiples, quiebres de nivel, o memoria larga (Hurst), la diferenciación estándar puede no ser suficiente.

8. **El pronóstico converge a la media a largo plazo.** Para horizontes muy largos, el intervalo de predicción del ARIMA(p,d,q) se expande indefinidamente (si $d \geq 1$), siendo de poca utilidad práctica más allá de unos pocos periodos.

21. Tres ejemplos con código Python

Los siguientes tres ejemplos utilizan el archivo `commodities_monthly.csv` que acompaña a este documento. Cada ejemplo incluye gráficas, interpretaciones y justificación de los órdenes elegidos.

21.1. Ejemplo 1: ARIMA para el precio del petróleo crudo (WTI)

Justificación de la serie. El petróleo crudo WTI no tiene estacionalidad mensual clara dominante (su patrón es más cíclico que estacional), pero es $I(1)$ en log-precios. Es el ejemplo ideal para un ARIMA ordinario. Se trabaja con los log-precios del petróleo.

```python
import pandas as pd
import numpy as np
```

```python
import matplotlib.pyplot as plt
import matplotlib.gridspec as gridspec
from statsmodels.tsa.statespace.sarimax import SARIMAX
from statsmodels.tsa.stattools import adfuller, kpss, acf, pacf
from statsmodels.graphics.tsaplots import plot_acf, plot_pacf
from statsmodels.tsa.seasonal import seasonal_decompose
from statsmodels.stats.diagnostic import acorr_ljungbox
from sklearn.metrics import mean_squared_error, mean_absolute_error

# ===== 1. Cargar datos =====
df = pd.read_csv('commodities_monthly.csv', parse_dates=['date'], index_col='date')
df.index.freq = 'MS'  # frecuencia mensual
oil = np.log(df['crude_oil_wti'])  # log-precios

# ===== 2. Grafica de la serie =====
fig, axes = plt.subplots(2, 1, figsize=(12, 7))
df['crude_oil_wti'].plot(ax=axes[0], title='Precio Petroleo WTI (USD/barril)', color='steelblue')
axes[0].set_ylabel('USD/barril')
oil.plot(ax=axes[1], title='Log-precio Petroleo WTI', color='darkorange')
axes[1].set_ylabel('ln(USD/barril)')
plt.tight_layout()
plt.savefig('ej1_serie.png', dpi=150, bbox_inches='tight')
plt.show()
# Interpretacion: La serie en niveles muestra tendencia y alta volatilidad.
# Los log-precios suavizan la varianza y presentan una tendencia estocastica clara.

# ===== 3. Pruebas ADF y KPSS =====
adf_result = adfuller(oil, autolag='AIC')
kpss_result = kpss(oil, regression='c', nlags='auto')
print(f"ADF  - estadistico: {adf_result[0]:.4f}, p-valor: {adf_result[1]:.4f}")
print(f"KPSS - estadistico: {kpss_result[0]:.4f}, p-valor: {kpss_result[1]:.4f}")
# ADF: no rechaza H0 (p > 0.05) => raiz unitaria probable
# KPSS: rechaza H0 (p < 0.05) => no estacionaria
# => Diferenciar: d=1

oil_diff = oil.diff().dropna()
adf_d1 = adfuller(oil_diff, autolag='AIC')
print(f"\nADF en diferencias: estadistico={adf_d1[0]:.4f}, p-valor={adf_d1[1]:.4f}")
# Tras diferenciar, ADF debe rechazar H0 => estacionaria => d=1 correcto

# ===== 4. ACF y PACF de la serie diferenciada =====
```

```python
fig, axes = plt.subplots(1, 2, figsize=(12, 4))
plot_acf(oil_diff, lags=24, ax=axes[0], title='ACF del log-retorno del petroleo')
plot_pacf(oil_diff, lags=24, ax=axes[1], title='PACF del log-retorno del petroleo',
          method='ywm')
plt.tight_layout()
plt.savefig('ej1_acf_pacf.png', dpi=150, bbox_inches='tight')
plt.show()
# Interpretacion: Si ACF y PACF son casi cero para todos los rezagos,
# los log-retornos son aproximadamente ruido blanco => ARIMA(0,1,0) o ARIMA(1,1,0).
# Si hay un pico en el rezago 1 de la ACF: considerar MA(1), i.e., ARIMA(0,1,1).
# Si hay un pico en la PACF: considerar AR(1), i.e., ARIMA(1,1,0).

# ===== 5. Descomposicion de la serie original =====
decomp = seasonal_decompose(oil, model='additive', period=12, extrapolate_trend='freq')
fig, axes = plt.subplots(4, 1, figsize=(12, 10))
decomp.observed.plot(ax=axes[0], title='Observada'); axes[0].set_ylabel('log P')
decomp.trend.plot(ax=axes[1], title='Tendencia'); axes[1].set_ylabel('log P')
decomp.seasonal.plot(ax=axes[2], title='Estacional'); axes[2].set_ylabel('')
decomp.resid.plot(ax=axes[3], title='Residuo'); axes[3].set_ylabel('')
plt.tight_layout()
plt.savefig('ej1_decomp.png', dpi=150, bbox_inches='tight')
plt.show()
# La tendencia es clara. El componente estacional del petroleo es debil
# (justifica usar ARIMA sin parte estacional).

# ===== 6. Seleccion de ordenes con AIC =====
train_size = int(len(oil) * 0.85)  # ~85% entrenamiento
train, test = oil.iloc[:train_size], oil.iloc[train_size:]

resultados = {}
for p in range(0, 3):
    for q in range(0, 3):
        try:
            mod = SARIMAX(train, order=(p, 1, q), trend='n',
                          enforce_stationarity=True, enforce_invertibility=True)
            res = mod.fit(disp=False)
            resultados[(p, 1, q)] = (res.aic, res.bic)
        except Exception:
```

```python
            pass

print("\nComparacion AIC/BIC:")
print(f"{'Orden':15s} {'AIC':10s} {'BIC':10s}")
for k, v in sorted(resultados.items(), key=lambda x: x[1][0]):
    print(f"ARIMA{str(k):10s} {v[0]:10.2f} {v[1]:10.2f}")

# ===== 7. Ajuste del modelo elegido =====
# Supongamos que ACF/PACF y AIC sugieren ARIMA(1,1,1)
model = SARIMAX(train, order=(1, 1, 1), trend='n',
                enforce_stationarity=True,
                   enforce_invertibility=True)
results = model.fit(disp=False)
print("\n", results.summary())

# ===== 8. Diagnostico de residuos =====
fig = results.plot_diagnostics(figsize=(12, 8))
plt.suptitle('Diagnostico de residuos - ARIMA(1,1,1) Petroleo',
   y=1.01)
plt.tight_layout()
plt.savefig('ej1_diagnosticos.png', dpi=150, bbox_inches='tight')
plt.show()

lb = acorr_ljungbox(results.resid, lags=[10], return_df=True)
print(f"\nLjung-Box (lag=10):
   estadistico={lb['lb_stat'].values[0]:.4f}, "
      f"p-valor={lb['lb_pvalue'].values[0]:.4f}")
# Si p-valor > 0.05: no rechazar H0 => residuos son ruido blanco
   => modelo OK

# ===== 9. Pronostico y evaluacion fuera de muestra =====
forecast_obj = results.get_forecast(steps=len(test))
fc_mean = forecast_obj.predicted_mean
fc_ci = forecast_obj.conf_int(alpha=0.05)

# Metricas en log-precios
rmse = np.sqrt(mean_squared_error(test, fc_mean))
mae = mean_absolute_error(test, fc_mean)
print(f"\nValidacion fuera de muestra (log-precios):")
print(f"RMSE = {rmse:.4f},  MAE = {mae:.4f}")

# Grafica del pronostico
fig, ax = plt.subplots(figsize=(12, 5))
train[-36:].plot(ax=ax, label='Entrenamiento (ultimos 3 anos)',
   color='steelblue')
test.plot(ax=ax, label='Real (validacion)', color='black')
fc_mean.plot(ax=ax, label='Pronostico ARIMA(1,1,1)',
   color='crimson', linestyle='--')
ax.fill_between(fc_ci.index, fc_ci.iloc[:, 0], fc_ci.iloc[:, 1],
                alpha=0.2, color='crimson', label='IC 95%')
ax.set_title('Pronostico log-precio Petroleo WTI - ARIMA(1,1,1)')
```

```python
ax.legend()
plt.tight_layout()
plt.savefig('ej1_forecast.png', dpi=150, bbox_inches='tight')
plt.show()

# ===== 10. Interpretacion del pronostico =====
# El pronostico en log-precios se convierte a niveles con exp():
fc_levels = np.exp(fc_mean)
real_levels = np.exp(test)
print(f"\nRMSE en niveles (USD/barril): "
      f"{np.sqrt(mean_squared_error(real_levels,
         fc_levels)):.2f}")
# Limitaciones: ARIMA no captura clusters de volatilidad del
   petroleo (2020, etc.)
# Considera extender a ARIMA-GARCH para modelar la varianza
   condicional.
```

Listing 1: Ejemplo 1: ARIMA para log-precios del petróleo WTI

Interpretación del ejemplo.

- La serie de log-precios del petróleo es $I(1)$: ADF no rechaza H_0 en niveles, pero sí en primeras diferencias.
- Los log-retornos ($d = 1$) tienen ACF y PACF con pocos picos significativos, consistentes con ARIMA(1,1,1) o incluso ARIMA(0,1,0).
- La descomposición muestra tendencia clara y componente estacional débil, justificando el uso de ARIMA (no SARIMA).
- El intervalo de predicción se expande con el horizonte, reflejando la incertidumbre creciente característica de los mercados de energía.
- **Limitación clave:** el modelo no captura la volatilidad extrema de 2020. Los residuos de ese periodo serán grandes. Para pronósticos de riesgo, considerar ARIMA-GARCH.

21.2. Ejemplo 2: SARIMA para el gas natural (Henry Hub)

Justificación de la serie. El gas natural tiene una estacionalidad invernal bien documentada: los precios suben en invierno por mayor demanda de calefacción y bajan en verano. Es el ejemplo por excelencia de un proceso con estacionalidad regular, ideal para SARIMA.

```python
import pandas as pd
import numpy as np
import matplotlib.pyplot as plt
from statsmodels.tsa.statespace.sarimax import SARIMAX
from statsmodels.tsa.stattools import adfuller, kpss
from statsmodels.graphics.tsaplots import plot_acf, plot_pacf
from statsmodels.tsa.seasonal import STL
from statsmodels.stats.diagnostic import acorr_ljungbox
from sklearn.metrics import mean_squared_error,
   mean_absolute_error

# ===== 1. Cargar y preparar datos =====
```

```python
df = pd.read_csv('commodities_monthly.csv', parse_dates=['date'], index_col='date')
df.index.freq = 'MS'
gas = np.log(df['natural_gas_henryhub'])

# ===== 2. Grafica de la serie =====
fig, ax = plt.subplots(figsize=(12, 4))
np.exp(gas).plot(ax=ax, color='forestgreen', linewidth=1)
ax.set_title('Gas Natural Henry Hub (USD/MMBtu)')
ax.set_ylabel('USD/MMBtu')
ax.axhline(np.exp(gas).mean(), color='red', linestyle='--', alpha=0.5, label='Media')
ax.legend()
plt.tight_layout()
plt.savefig('ej2_serie.png', dpi=150, bbox_inches='tight')
plt.show()
# Se observa: tendencia estocastica + picos invernales recurrentes cada 12 meses.

# ===== 3. Descomposicion STL =====
stl = STL(gas, period=12, robust=True)
stl_result = stl.fit()
fig = stl_result.plot()
fig.set_size_inches(12, 9)
fig.suptitle('Descomposicion STL - Log Gas Natural', y=1.01)
plt.tight_layout()
plt.savefig('ej2_stl.png', dpi=150, bbox_inches='tight')
plt.show()
# Interpretacion: La tendencia es la componente dominante a largo plazo.
# El componente estacional muestra pico claro en enero-febrero (invierno norte).
# El residuo contiene eventos como el spike de 2022 (guerra en Ucrania).

# ===== 4. Fuerza estacional =====
seasonal_strength = max(0, 1 - np.var(stl_result.resid) /
                        np.var(stl_result.seasonal + stl_result.resid))
print(f"Fuerza estacional (FS) = {seasonal_strength:.4f}")
# FS > 0.6 => estacionalidad fuerte => usar SARIMA

# ===== 5. Pruebas de estacionariedad =====
adf_gas = adfuller(gas, autolag='AIC')
print(f"ADF niveles: estadistico={adf_gas[0]:.4f}, p-valor={adf_gas[1]:.4f}")
# Probable raiz unitaria => d=1

gas_diff = gas.diff().dropna()
gas_diff_s = gas_diff.diff(12).dropna()  # doble diferencia

```

```python
adf_dd = adfuller(gas_diff_s, autolag='AIC')
print(f"ADF doble-diferencia: estadistico={adf_dd[0]:.4f}, p-valor={adf_dd[1]:.4f}")
# Estacionaria tras d=1, D=1

# ===== 6. ACF y PACF de la serie doblemente diferenciada =====
fig, axes = plt.subplots(1, 2, figsize=(12, 4))
plot_acf(gas_diff_s, lags=36, ax=axes[0],
         title='ACF - Gas Natural (d=1, D=1)')
plot_pacf(gas_diff_s, lags=36, ax=axes[1],
          title='PACF - Gas Natural (d=1, D=1)', method='ywm')
plt.tight_layout()
plt.savefig('ej2_acf_pacf.png', dpi=150, bbox_inches='tight')
plt.show()
# Interpretacion:
# - Rezagos ordinarios 1-5: guian p y q (partes no estacionales).
# - Rezago 12: un pico significativo en ACF y decaimiento en PACF
#   sugiere SMA(1) => Q=1. Si corte en PACF en lag 12: SAR(1) => P=1.
# - Modelo candidato: SARIMA(1,1,1)(0,1,1)_12 (modelo de Airline modificado)

# ===== 7. Division entrenamiento / validacion =====
train_size = int(len(gas) * 0.85)
train = gas.iloc[:train_size]
test = gas.iloc[train_size:]

# ===== 8. Ajuste del modelo SARIMA =====
# Modelo candidato basado en ACF/PACF: SARIMA(1,1,1)(0,1,1)_12
model = SARIMAX(train, order=(1, 1, 1), seasonal_order=(0, 1, 1, 12),
                trend='n', enforce_stationarity=True, enforce_invertibility=True)
results = model.fit(disp=False)
print(results.summary())

# ===== 9. Diagnostico de residuos =====
fig = results.plot_diagnostics(figsize=(12, 8))
plt.suptitle('Diagnostico de residuos - SARIMA(1,1,1)(0,1,1)_12 Gas Natural')
plt.tight_layout()
plt.savefig('ej2_diagnosticos.png', dpi=150, bbox_inches='tight')
plt.show()

lb = acorr_ljungbox(results.resid, lags=[12, 24], return_df=True)
print("\nLjung-Box:")
print(lb[['lb_stat', 'lb_pvalue']])

# ===== 10. Pronostico =====
fc_obj = results.get_forecast(steps=len(test))
fc_mean = fc_obj.predicted_mean
```

```python
fc_ci = fc_obj.conf_int(alpha=0.05)

fig, ax = plt.subplots(figsize=(12, 5))
np.exp(train[-48:]).plot(ax=ax, label='Entrenamiento', color='forestgreen')
np.exp(test).plot(ax=ax, label='Real', color='black')
np.exp(fc_mean).plot(ax=ax, label='SARIMA Pronostico', color='darkorange',
                     linestyle='--')
ax.fill_between(fc_ci.index,
                np.exp(fc_ci.iloc[:, 0]),
                np.exp(fc_ci.iloc[:, 1]),
                alpha=0.2, color='darkorange', label='IC 95%')
ax.set_title('Pronostico Gas Natural - SARIMA(1,1,1)(0,1,1)_12')
ax.set_ylabel('USD/MMBtu')
ax.legend()
plt.tight_layout()
plt.savefig('ej2_forecast.png', dpi=150, bbox_inches='tight')
plt.show()

# ===== 11. Evaluacion =====
rmse = np.sqrt(mean_squared_error(test, fc_mean))
mae = mean_absolute_error(test, fc_mean)
print(f"RMSE (log) = {rmse:.4f}")
print(f"MAE  (log) = {mae:.4f}")

# En niveles:
rmse_niv = np.sqrt(mean_squared_error(np.exp(test), np.exp(fc_mean)))
print(f"RMSE (USD/MMBtu) = {rmse_niv:.4f}")

# ===== 12. Interpretacion del pronostico =====
print(f"\nParametros estimados:")
print(f"phi_1 (AR) = {results.params.get('ar.L1', 'NA'):.4f}")
print(f"theta_1 (MA) = {results.params.get('ma.L1', 'NA'):.4f}")
print(f"Theta_1 (SMA12) = {results.params.get('ma.S.L12', 'NA'):.4f}")
# Theta_1 negativo (tipicamente -0.5 a -0.9) indica que un error
# positivo en enero del a o pasado reduce el pronostico del siguiente enero:
# el modelo corrige la subestimacion/sobreestimacion estacional pasada.
```

Listing 2: Ejemplo 2: SARIMA para log-precios del gas natural

Interpretación del ejemplo.

- La STL muestra claramente la estacionalidad invernal del gas natural: picos en enero-febrero, mínimos en mayo-agosto.
- Con $d = 1$ y $D = 1$ la serie es estacionaria. La doble diferenciación elimina tanto la tendencia de largo plazo como el ciclo estacional anual.
- El modelo SARIMA$(1,1,1)(0,1,1)_{12}$ captura la dinámica ordinaria y la correción de errores estacionales anuales (término Θ_1).

- El pronóstico fuera de muestra reproduce los picos invernales, lo que sería imposible con un ARIMA sin componente estacional.
- **Limitación:** el spike de precios de 2022 por la guerra en Ucrania es un quiebre estructural que ningún modelo ARIMA/SARIMA puede anticipar. Los residuos de ese periodo serán muy grandes.

21.3. Ejemplo 3: Comparación ARIMA vs. SARIMA para el oro

Justificación. El precio del oro no tiene estacionalidad mensual marcada, pero su comportamiento es de tendencia alcista de largo plazo. Este ejemplo ilustra el proceso completo de selección: ACF/PACF, comparación AIC/BIC, y validación fuera de muestra entre un ARIMA y un SARIMA para decidir cuál modelo usar.

```python
import pandas as pd
import numpy as np
import matplotlib.pyplot as plt
from statsmodels.tsa.statespace.sarimax import SARIMAX
from statsmodels.tsa.stattools import adfuller, kpss
from statsmodels.graphics.tsaplots import plot_acf, plot_pacf
from statsmodels.tsa.seasonal import seasonal_decompose, STL
from statsmodels.stats.diagnostic import acorr_ljungbox
from sklearn.metrics import mean_squared_error,
    mean_absolute_error
import itertools
import warnings
warnings.filterwarnings('ignore')

# ===== 1. Cargar datos =====
df = pd.read_csv('commodities_monthly.csv',
    parse_dates=['date'], index_col='date')
df.index.freq = 'MS'
gold = np.log(df['gold_usd_oz'])

# ===== 2. Analisis exploratorio =====
fig, axes = plt.subplots(2, 1, figsize=(12, 7))
np.exp(gold).plot(ax=axes[0], color='goldenrod',
                  title='Precio del Oro (USD/oz)')
gold.plot(ax=axes[1], color='darkgoldenrod',
          title='Log-precio del Oro')
plt.tight_layout()
plt.savefig('ej3_serie.png', dpi=150, bbox_inches='tight')
plt.show()

# ===== 3. Descomposicion =====
decomp = seasonal_decompose(gold, model='additive', period=12,
                            extrapolate_trend='freq')
fig, axes = plt.subplots(4, 1, figsize=(12, 10))
for ax, (comp, label) in zip(axes, [
    (decomp.observed, 'Observada'),
    (decomp.trend, 'Tendencia'),
    (decomp.seasonal, 'Estacional'),
```

```
    (decomp.resid, 'Residuo')]):
    comp.plot(ax=ax, color='goldenrod')
    ax.set_title(label)
plt.tight_layout()
plt.savefig('ej3_decomp.png', dpi=150, bbox_inches='tight')
plt.show()
# La componente estacional del oro es muy pequena relativa a tendencia y residuo.
# Esto sugiere que ARIMA puede ser tan bueno como SARIMA.

# ===== 4. Fuerza estacional del oro =====
stl_gold = STL(gold, period=12, robust=True).fit()
fs_gold = max(0, 1 - np.var(stl_gold.resid) /
                np.var(stl_gold.seasonal + stl_gold.resid))
print(f"Fuerza estacional del oro: FS = {fs_gold:.4f}")
# Si FS < 0.4 => estacionalidad debil => ARIMA deberia ser suficiente.

# ===== 5. Pruebas de estacionariedad =====
adf_gold = adfuller(gold, autolag='AIC')
kpss_gold = kpss(gold, regression='c', nlags='auto')
print(f"ADF (niveles): estadistico={adf_gold[0]:.4f}, p-valor={adf_gold[1]:.4f}")
print(f"KPSS(niveles): estadistico={kpss_gold[0]:.4f}, p-valor={kpss_gold[1]:.4f}")
# Ambos confirman raiz unitaria => d=1

gold_diff = gold.diff().dropna()
adf_d1 = adfuller(gold_diff, autolag='AIC')
print(f"ADF (d=1): estadistico={adf_d1[0]:.4f}, p-valor={adf_d1[1]:.4f}")

# ===== 6. ACF y PACF =====
fig, axes = plt.subplots(2, 2, figsize=(14, 8))
plot_acf(gold, lags=36, ax=axes[0, 0], title='ACF - Oro (niveles)')
plot_pacf(gold, lags=36, ax=axes[0, 1], title='PACF - Oro (niveles)', method='ywm')
plot_acf(gold_diff, lags=36, ax=axes[1, 0], title='ACF - Oro (d=1)')
plot_pacf(gold_diff, lags=36, ax=axes[1, 1], title='PACF - Oro (d=1)', method='ywm')
plt.tight_layout()
plt.savefig('ej3_acf_pacf.png', dpi=150, bbox_inches='tight')
plt.show()
# En niveles: ACF decae lentamente => no estacionaria.
# En d=1: ACF y PACF con pocos picos => log-retornos casi ruido blanco.
# No hay picos prominentes en rezagos 12, 24 => confirma estacionalidad debil.

```

```python
# ===== 7. Division de muestra =====
train_size = int(len(gold) * 0.82)
train, test = gold.iloc[:train_size], gold.iloc[train_size:]
print(f"Entrenamiento: {len(train)} obs. | Validacion: {len(test)} obs.")

# ===== 8. Busqueda de mejores ordenes ARIMA =====
best_aic = np.inf
best_params = None

for p, q in itertools.product(range(3), range(3)):
    try:
        mod = SARIMAX(train, order=(p, 1, q), trend='n',
                      enforce_stationarity=True, enforce_invertibility=True)
        res = mod.fit(disp=False)
        if res.aic < best_aic:
            best_aic = res.aic
            best_params = (p, 1, q)
    except Exception:
        pass

print(f"\nMejor ARIMA por AIC: ARIMA{best_params}, AIC={best_aic:.2f}")

# ===== 9. Ajuste ARIMA optimo =====
arima_mod = SARIMAX(train, order=best_params, trend='n',
                    enforce_stationarity=True, enforce_invertibility=True)
arima_res = arima_mod.fit(disp=False)

# ===== 10. Ajuste SARIMA con componente estacional debil =====
# Probar SARIMA(1,1,1)(0,1,1)_12 para comparar
sarima_mod = SARIMAX(train, order=(1, 1, 1), seasonal_order=(0, 1, 1, 12),
                     trend='n', enforce_stationarity=True,
                     enforce_invertibility=True)
sarima_res = sarima_mod.fit(disp=False)

# ===== 11. Comparacion dentro de muestra =====
print("\nComparacion de modelos:")
print(f"{'Modelo':30s} {'AIC':8s} {'BIC':8s}")
print(f"{'ARIMA' + str(best_params):30s} {arima_res.aic:8.2f} {arima_res.bic:8.2f}")
print(f"{'SARIMA(1,1,1)(0,1,1)_12':30s} {sarima_res.aic:8.2f} {sarima_res.bic:8.2f}")
# Si el ARIMA tiene AIC/BIC comparable o mejor que el SARIMA,
# la componente estacional es innecesaria => principio de parsimonia.

# ===== 12. Diagnostico de residuos para ambos modelos =====
```

```python
for label, res in [('ARIMA', arima_res), ('SARIMA', sarima_res)]:
    lb = acorr_ljungbox(res.resid, lags=[10, 20], return_df=True)
    print(f"\n{label} - Ljung-Box:")
    print(lb[['lb_stat', 'lb_pvalue']].to_string())

# ===== 13. Pronostico fuera de muestra: ambos modelos =====
h = len(test)
fc_arima = arima_res.get_forecast(steps=h)
fc_sarima = sarima_res.get_forecast(steps=h)

# Metricas
def calc_metrics(actual, predicted):
    rmse = np.sqrt(mean_squared_error(actual, predicted))
    mae = mean_absolute_error(actual, predicted)
    return rmse, mae

rmse_a, mae_a = calc_metrics(test, fc_arima.predicted_mean)
rmse_s, mae_s = calc_metrics(test, fc_sarima.predicted_mean)

print("\nValidacion fuera de muestra (log-precios):")
print(f"{'Modelo':30s} {'RMSE':8s} {'MAE':8s}")
print(f"{'ARIMA' + str(best_params):30s} {rmse_a:8.4f} {mae_a:8.4f}")
print(f"{'SARIMA(1,1,1)(0,1,1)_12':30s} {rmse_s:8.4f} {mae_s:8.4f}")

# ===== 14. Grafica comparativa de pronosticos =====
fig, axes = plt.subplots(2, 1, figsize=(12, 9), sharex=True)

for ax, (label, fc_obj, color) in zip(axes, [
    ('ARIMA', fc_arima, 'steelblue'),
    ('SARIMA(1,1,1)(0,1,1)_12', fc_sarima, 'darkorange')]):
    fc_mean = fc_obj.predicted_mean
    fc_ci = fc_obj.conf_int(alpha=0.05)
    np.exp(train[-36:]).plot(ax=ax, color='darkgray', label='Entrenamiento')
    np.exp(test).plot(ax=ax, color='black', label='Real')
    np.exp(fc_mean).plot(ax=ax, color=color, linestyle='--',
                         label=f'Pronostico {label}')
    ax.fill_between(fc_ci.index,
                    np.exp(fc_ci.iloc[:, 0]),
                    np.exp(fc_ci.iloc[:, 1]),
                    alpha=0.2, color=color)
    ax.set_title(f'Pronostico Oro - {label}')
    ax.set_ylabel('USD/oz')
    ax.legend()

plt.tight_layout()
plt.savefig('ej3_forecast_comparativo.png', dpi=150, bbox_inches='tight')
plt.show()
```

```python

# ===== 15. Conclusion del ejemplo =====
# Si el ARIMA tiene AIC/BIC similar o mejor que el SARIMA Y menor RMSE
# fuera de muestra => el componente estacional del oro no mejora el pronostico.
# Si el SARIMA gana en RMSE: la estacionalidad debil del oro si aporta.
# Conclusion practica: para el oro, ARIMA es generalmente suficiente;
# el exceso de parametros del SARIMA introduce varianza sin beneficio.
print("\nConclusion: El modelo con menor RMSE fuera de muestra y mejor")
print("AIC/BIC es el preferido. La parsimonia sugiere ARIMA si la")
print("diferencia con SARIMA es marginal.")
```

Listing 3: Ejemplo 3: Comparacion ARIMA vs. SARIMA - Oro

Interpretación del ejemplo.

- La fuerza estacional del oro es baja ($FS < 0.3$ típicamente). La descomposición confirma que la tendencia domina y que la estacionalidad mensual es casi despreciable.
- Los log-retornos del oro tienen ACF y PACF con muy pocos picos, lo que indica que el proceso se acerca a un paseo aleatorio.
- Comparando ARIMA vs. SARIMA en RMSE fuera de muestra: si el ARIMA es igual de bueno o mejor, el principio de parsimonia lo justifica.
- Este ejemplo ilustra que el SARIMA no siempre mejora el pronóstico; añadir componentes estacionales a una serie sin estacionalidad real empeora los resultados.

22. Glosario de notación y conceptos

Símbolo/Término	Definición
$\{Y_t\}$	Proceso estocástico en tiempo discreto
μ	Media del proceso (constante bajo estacionariedad débil)
$\gamma(k)$	Autocovarianza en el rezago k: $\mathrm{Cov}(Y_t, Y_{t-k})$
$\rho(k)$	Autocorrelación en el rezago k: $\gamma(k)/\gamma(0)$
$\alpha(k)$	Autocorrelación parcial en el rezago k (PACF)
B	Operador de rezago: $BY_t = Y_{t-1}$
Δ	Diferencia ordinaria: $(1-B)Y_t = Y_t - Y_{t-1}$
Δ_s	Diferencia estacional: $(1-B^s)Y_t = Y_t - Y_{t-s}$
ε_t	Ruido blanco: media cero, varianza σ^2, incorrelacionado
φ_i	Coeficiente AR ordinario (rezago i)
θ_i	Coeficiente MA ordinario (rezago i)
Φ_i	Coeficiente AR estacional (rezago is)
Θ_i	Coeficiente MA estacional (rezago is)

Símbolo/Término	Definición
p	Orden autorregresivo ordinario
d	Orden de diferenciación ordinaria
q	Orden de promedio móvil ordinario
P	Orden autorregresivo estacional
D	Orden de diferenciación estacional
Q	Orden de promedio móvil estacional
s	Periodo estacional (e.g., 12 para series mensuales)
$I(d)$	Serie integrada de orden d
$I(0)$	Serie estacionaria (integrada de orden cero)
$I(1)$	Serie con una raíz unitaria (primera diferencia es estacionaria)
AIC	Criterio de información de Akaike: $-2\ln\hat{L} + 2k$
BIC	Criterio de información bayesiano (Schwarz): $-2\ln\hat{L} + k\ln n$
ADF	Prueba de Dickey-Fuller aumentada: H_0: raíz unitaria
KPSS	Prueba de Kwiatkowski-Phillips-Schmidt-Shin: H_0: estacionaria
Ljung-Box	Prueba de independencia de residuos: H_0: ruido blanco
RMSE	Raíz del error cuadrático medio: $\sqrt{\frac{1}{n}\sum(Y_t - \hat{Y}_t)^2}$
MAE	Error absoluto medio: $\frac{1}{n}\sum\lvert Y_t - \hat{Y}_t\rvert$
STL	Seasonal and Trend decomposition using Loess
Box-Jenkins	Procedimiento iterativo de identificación, estimación, diagnóstico
Parsimonia	Preferencia por el modelo con menos parámetros entre los igualmente buenos
FS	Fuerza estacional: $\text{máx}\{0, 1 - \text{Var}(\hat{R})/\text{Var}(\hat{S} + \hat{R})\}$

23. Lista de verificación de modelado

Checklist: del dato crudo al pronóstico

- ☐ **Carga y limpieza.** Verificar frecuencia, valores faltantes, y formato de la serie. Identificar la variable de interés (precios, log-precios, retornos).
- ☐ **Visualización inicial.** Graficar Y_t y $\ln Y_t$. ¿Se observa tendencia? ¿Estacionalidad visual? ¿Cambios abruptos de nivel o varianza?
- ☐ **Descomposición.** Aplicar descomposición clásica o STL. Calcular fuerza estacional FS. Si $FS > 0.5$: considerar SARIMA o STL+ARIMA.
- ☐ **Transformación.** ¿Usar niveles, log-precios, o retornos? Justificar con la gráfica de varianza condicional. Aplicar logaritmo si la varianza crece con el nivel.
- ☐ **Pruebas de estacionariedad.** Aplicar ADF y KPSS. Determinar d (y D si

hay estacionalidad). Nunca sobre-diferenciar.

- ☐ **ACF y PACF.** Graficar sobre la serie diferenciada. Identificar cortes ordinarios (para p y q) y cortes en múltiplos de s (para P y Q). Proponer 2-4 modelos candidatos.
- ☐ **División de muestra.** Reservar el último 15-20 % de las observaciones para validación fuera de muestra. **No usar la muestra de validación para ajustar el modelo.**
- ☐ **Estimación y comparación.** Estimar cada modelo candidato. Comparar AIC y BIC. Ante empate, preferir el modelo más parsimonioso.
- ☐ **Diagnóstico de residuos.** Verificar: gráfica de residuos sin tendencia/varianza cambiante, histograma y Q-Q plot aproximadamente normales, ACF de residuos dentro de bandas, Ljung-Box con p-valor > 0.05. Si falla: revisar órdenes y regresar a la etapa de ACF/PACF.
- ☐ **Validación fuera de muestra.** Calcular RMSE y MAE en la muestra de validación. El modelo con mejor RMSE fuera de muestra es el definitivo.
- ☐ **Pronóstico.** Generar pronóstico puntual e intervalos de predicción al 80 % y 95 %. Graficar el "fan chart" (abanico de pronósticos).
- ☐ **Interpretación y limitaciones.** Explicar los parámetros estimados en términos económicos. Mencionar explícitamente qué no captura el modelo (volatilidad condicional, quiebres, asimetría). Proponer extensiones si son relevantes.

24. Síntesis final

Este documento ha cubierto el flujo completo del análisis de series de tiempo con modelos ARIMA y SARIMA, desde los fundamentos matemáticos hasta la aplicación en datos de commodities. Los puntos clave a retener son:

1. Estacionariedad es el punto de partida. Todo análisis comienza verificando si la serie es $I(0)$ o $I(1)$ (o $I(2)$). Las pruebas ADF y KPSS se complementan: usarlas juntas reduce el riesgo de conclusiones erróneas.

2. La diferenciación es medicina, no vitamina. Diferenciar de más es tan perjudicial como no diferenciar. La serie diferenciada correctamente debe mostrar ACF y PACF "legibles" (sin decaimiento lento masivo).

3. ACF/PACF dan candidatos; AIC/BIC los filtran; los residuos deciden. Ninguna herramienta sola es suficiente. El proceso de Box-Jenkins es iterativo y requiere criterio, no mecánica.

4. La parsimonia protege el pronóstico. Los modelos sobreparametrizados memorizan el ruido de la muestra y fallan fuera de ella. Para commodities sujetos a quiebres estructurales frecuentes, la parsimonia es especialmente valiosa.

5. SARIMA no siempre es mejor que ARIMA. Añadir componentes estacionales a una serie sin estacionalidad real empeora el pronóstico. La fuerza estacional FS y la

validación fuera de muestra guían la decisión.

6. Los modelos ARIMA/SARIMA tienen límites claros. No capturan volatilidad condicional (GARCH), quiebres estructurales (Markov-switching), ni asimetría en choques. Para mercados de energía y metales sometidos a episodios extremos, considerar extensiones es buena práctica, no un lujo.

7. El pronóstico es incierto. Los intervalos de predicción se expanden con el horizonte. Usar el punto central como pronóstico puntual es razonable; usar el intervalo completo es esencial para decisiones de cobertura y gestión de riesgos.