Universidad Panamericana
Ciudad UP · Facultad de Ciencias Empresariales

Tarea

Series de Tiempo para Finanzas

ARIMA(p, d, q) · SARIMA · SARIMAX · Pronóstico

Alumno: Guillermo García Ramos de la Rosa

Semestre: Octavo semestre de Finanzas Cuantitativas

Materia: Series de Tiempo para Finanzas

Profesor: Dr. César Galindo

Fecha de entrega: 13 de abril de 2026

Periodo: Verano 2026

1. Procesos estacionarios y fundamentos

Estacionariedad débil (de covarianza). El proceso $\{Y_t\}_{t\in\mathbb{Z}}$ es débilmente estacionario si: (i) $\mathbb{E}[Y_t] = \mu$ para todo t; (ii) $\mathrm{Cov}(Y_t, Y_{t-k}) = \gamma(k)$ depende solo de k.

Estacionariedad estricta. La distribución conjunta de $(Y_{t_1}, \ldots, Y_{t_m})$ coincide con la de $(Y_{t_1+h}, \ldots, Y_{t_m+h})$ para todo h y toda elección de índices.

ACF y PACF. $\rho(k) = \gamma(k)/\gamma(0)$: función de autocorrelación (ACF). La función de autocorrelación parcial (PACF) $\alpha(k)$ es la correlación entre Y_t e Y_{t-k} eliminando el efecto lineal de $Y_{t-1}, \ldots, Y_{t-k+1}$.

Operador de rezago. $BY_t = Y_{t-1}$; $B^kY_t = Y_{t-k}$; $\Delta = (1 - B)$.

Ruido blanco. $\{\varepsilon_t\} \sim \mathrm{WN}(0, \sigma^2)$: media cero, varianza σ^2, no correlacionado.

Procesos ARMA(p, q). $\Phi(B)Y_t = \Theta(B)\varepsilon_t$, donde $\Phi(z) = 1 - \phi_1 z - \cdots - \phi_p z^p$ y $\Theta(z) = 1 + \theta_1 z + \cdots + \theta_q z^q$. Condición de estacionariedad: raíces de $\Phi(z)$ fuera del círculo unitario. Condición de invertibilidad: raíces de $\Theta(z)$ fuera del círculo unitario.

Patrones de identificación.

- AR(p): PACF se corta en el rezago p; ACF decae.
- MA(q): ACF se corta en el rezago q; PACF decae.
- ARMA(p, q): ambas ACF y PACF decaen sin corte abrupto.
- Ruido blanco: ACF y PACF ≈ 0 para todo $k \geq 1$.

Raíz unitaria. Y_t tiene raíz unitaria si $\Phi(1) = 0$; implica no estacionariedad. La primera diferencia ΔY_t suele ser estacionaria (proceso $I(1)$).

Ejercicio 1.1 · Estacionariedad, ACF y PACF

Se solicita: *Definir estacionariedad débil y estricta; dar un ejemplo débilmente estacionario no estrictamente estacionario; demostrar* $|\rho(k)| \leq 1$ *y* $\rho(k) = \rho(-k)$*; calcular* $\mathrm{Var}(Y_t)$, $\mathrm{Cov}(Y_t, Y_{t-1})$ *y demostrar* $\rho(k) = 0.6^k$ *para el AR(1) dado; describir los patrones ACF/PACF de AR(1), MA(1) y ruido blanco.*

(a) Estacionariedad débil y estricta.

La *estacionariedad débil* (o de covarianza) exige dos condiciones:

$$\mathbb{E}[Y_t] = \mu \quad \forall\, t, \qquad \mathrm{Cov}(Y_t, Y_{t-k}) = \gamma(k) \text{ (depende solo de } k).$$

La *estacionariedad estricta* exige que para cualquier m, $t_1, \ldots, t_m$ y h,

$$(Y_{t_1}, \ldots, Y_{t_m}) \overset{d}{=} (Y_{t_1+h}, \ldots, Y_{t_m+h}).$$

La estricta implica la débil, pero no viceversa.

Ejemplo. Sean Z_1 y Z_2 variables independientes con $\mathbb{E}[Z_i] = 0$, $\mathrm{Var}(Z_i) = 1$, pero con distribuciones distintas entre sí. Definamos

$$Y_t = \begin{cases} Z_1 & t \text{ par}, \\ Z_2 & t \text{ impar}. \end{cases}$$

Se tiene $\mathbb{E}[Y_t] = 0$ y $\mathrm{Var}(Y_t) = 1$ para todo t. Para k impar, $\mathrm{Cov}(Y_t, Y_{t-k}) = 0$; para k par, $\mathrm{Cov}(Y_t, Y_{t-k}) = 1$. La covarianza depende solo de k, luego el proceso es *débilmente* estacionario. Sin embargo, la distribución marginal de Y_t cambia con la paridad de t: en t par es la de Z_1 y en t impar la de Z_2, que son distintas, por lo que no es *estrictamente* estacionario.

(b) Demostración de $|\rho(k)| \leq 1$ y $\rho(k) = \rho(-k)$.

Desigualdad. Por la desigualdad de Cauchy–Schwarz,

$$|\,\mathrm{Cov}(Y_t, Y_{t-k})| \;\leq\; \sqrt{\mathrm{Var}(Y_t)\;\mathrm{Var}(Y_{t-k})}.$$

Bajo estacionariedad débil, $\mathrm{Var}(Y_t) = \mathrm{Var}(Y_{t-k}) = \gamma(0)$, de modo que $|\gamma(k)| \leq \gamma(0)$ y, dividiendo entre $\gamma(0) > 0$,

$$\boxed{|\rho(k)| \leq 1.}$$

Simetría. Por propiedades de la covarianza, $\gamma(-k) = \mathrm{Cov}(Y_t, Y_{t+k}) = \mathrm{Cov}(Y_{t+k}, Y_t) = \gamma(k)$, de donde

$$\boxed{\rho(-k) = \rho(k).}$$

(c) AR(1): $Y_t = 0.6\,Y_{t-1} + \varepsilon_t$, $\varepsilon_t \sim \mathrm{WN}(0, \sigma^2)$.

Como $|\phi| = 0.6 < 1$, el proceso es estacionario.

Media. $\mathbb{E}[Y_t] = 0.6\;\mathbb{E}[Y_{t-1}]$; la media estacionaria satisface $\mu = 0.6\mu$, luego $\mu = 0$.

Varianza. Elevando al cuadrado y tomando esperanza:

$$\gamma(0) = 0.36\,\gamma(0) + \sigma^2 \implies \gamma(0) = \frac{\sigma^2}{0.64} = \frac{25\,\sigma^2}{16}.$$

Covarianza de rezago 1. Multiplicando $Y_t Y_{t-1}$ y tomando esperanza:

$$\gamma(1) = 0.6\,\gamma(0) = \frac{15\,\sigma^2}{16}.$$

Fórmula general. Para $k \geq 1$,

$$\gamma(k) = \mathrm{Cov}(0.6\,Y_{t-1} + \varepsilon_t,\, Y_{t-k}) = 0.6\,\gamma(k-1) + \underbrace{\mathrm{Cov}(\varepsilon_t, Y_{t-k})}_{=0} = 0.6\,\gamma(k-1).$$

Aplicando la recurrencia repetidamente: $\gamma(k) = 0.6^k\,\gamma(0)$, y por tanto

$$\boxed{\rho(k) = 0.6^k, \quad k \geq 0.}$$

(d) Patrones ACF/PACF.

- **AR(1) con $\phi > 0$:** ACF decae exponencialmente, $\rho(k) = \phi^k > 0$. PACF se corta abruptamente en el rezago 1 (la correlación parcial es exactamente ϕ_1 en $k = 1$ y cero para $k \geq 2$).

- **MA(1) con $\theta > 0$:** ACF es no nula solo en $k = 1$ (se corta tras el rezago 1). PACF decae gradualmente.
- **Ruido blanco:** ACF y PACF son aproximadamente cero para todo $k \geq 1$.

Estos patrones permiten identificar el orden del modelo porque la estructura AR deja una huella nítida en la PACF (corte en p) y la estructura MA en la ACF (corte en q). Con ambas funciones se aplica el procedimiento de Box–Jenkins para seleccionar p y q.

Resultado final. $\mathrm{Var}(Y_t) = \frac{25\sigma^2}{16}$; $\mathrm{Cov}(Y_t, Y_{t-1}) = \frac{15\sigma^2}{16}$; $\rho(k) = 0.6^k$.

Ejercicio 1.2 · Procesos AR, MA y ARMA

Se solicita: *Para el AR(2) dado, calcular raíces de $\Phi(z)$ y determinar estacionariedad; para el MA(2) dado, calcular varianza y covarianzas; enunciar la condición de invertibilidad de un MA(q); demostrar la representación MA(∞) del AR(1) estacionario.*

(a) AR(2): $Y_t = 1.2\,Y_{t-1} - 0.32\,Y_{t-2} + \varepsilon_t$.

El polinomio AR es $\Phi(z) = 1 - 1.2z + 0.32z^2$. Encontramos sus raíces resolviendo $0.32z^2 - 1.2z + 1 = 0$:

$$z = \frac{1.2 \pm \sqrt{1.44 - 1.28}}{0.64} = \frac{1.2 \pm 0.4}{0.64}.$$

$$z_1 = \frac{1.6}{0.64} = 2.5, \qquad z_2 = \frac{0.8}{0.64} = 1.25.$$

Como $|z_1| = 2.5 > 1$ y $|z_2| = 1.25 > 1$, ambas raíces están fuera del círculo unitario.

Resultado final. El proceso AR(2) **es estacionario**; raíces $z_1 = 2.5$ y $z_2 = 1.25$.

(b) MA(2): $Y_t = \varepsilon_t + 0.5\,\varepsilon_{t-1} - 0.3\,\varepsilon_{t-2}$.

Con coeficientes $\psi_0 = 1$, $\psi_1 = 0.5$, $\psi_2 = -0.3$:

$$\gamma(0) = \sigma^2(\psi_0^2 + \psi_1^2 + \psi_2^2) = \sigma^2(1 + 0.25 + 0.09) = 1.34\,\sigma^2.$$

$$\gamma(1) = \sigma^2(\psi_0\psi_1 + \psi_1\psi_2) = \sigma^2(0.5 - 0.15) = 0.35\,\sigma^2.$$

$$\gamma(2) = \sigma^2\psi_0\psi_2 = (1)(-0.3)\,\sigma^2 = -0.3\,\sigma^2.$$

$$\gamma(k) = 0 \quad \forall\, k \geq 3.$$

Resultado final. $\mathrm{Var}(Y_t) = 1.34\sigma^2$; $\mathrm{Cov}(Y_t, Y_{t-1}) = 0.35\sigma^2$; $\mathrm{Cov}(Y_t, Y_{t-2}) = -0.3\sigma^2$; $\mathrm{Cov}(Y_t, Y_{t-k}) = 0$ para $k \geq 3$.

(c) Invertibilidad de un MA(q).

El proceso $Y_t = \Theta(B)\varepsilon_t$ con $\Theta(z) = 1 + \theta_1 z + \cdots + \theta_q z^q$ es *invertible* si todas las raíces de $\Theta(z)$ satisfacen $|z| > 1$, es decir, están fuera del círculo unitario. Bajo esta condición, existe una representación AR(∞) convergente $\varepsilon_t = \Pi(B)Y_t$, que garantiza que las innovaciones queden unívocamente identificadas a partir de la historia observada de Y_t. Sin invertibilidad, distintos

conjuntos de parámetros pueden generar la misma estructura de autocovarianza, lo que hace ambigua la identificación del modelo y vuelve inválido el pronóstico basado en innovaciones.

(d) Representación MA(∞) del AR(1).

Partimos de $(1-\phi B)Y_t = \varepsilon_t$ con $|\phi| < 1$. El inverso formal del operador $(1-\phi B)$ es la serie geométrica convergente:

$$(1-\phi B)^{-1} = \sum_{j=0}^{\infty} \phi^j B^j.$$

Aplicando a ambos lados: $Y_t = \sum_{j=0}^{\infty} \phi^j \varepsilon_{t-j}$.

La misma conclusión se obtiene por sustitución iterada. Partiendo de $Y_t = \phi Y_{t-1} + \varepsilon_t$ y retrocediendo n pasos:

$$Y_t = \phi^n Y_{t-n} + \sum_{j=0}^{n-1} \phi^j \varepsilon_{t-j}.$$

Como $|\phi| < 1$, $\phi^n Y_{t-n} \to 0$, luego:

$$\boxed{Y_t = \sum_{j=0}^{\infty} \phi^j \varepsilon_{t-j}, \quad \psi_j = \phi^j.}$$

Ejercicio 1.3 · Raíces unitarias y prueba de Dickey–Fuller

Se solicita: *Demostrar que la caminata aleatoria no es estacionaria calculando* $\mathrm{Var}(Y_t)$ *y* $\mathrm{Cov}(Y_t, Y_s)$*; mostrar que* $\Delta Y_t = \varepsilon_t$*; explicar por qué el estadístico ADF no sigue una distribución t clásica bajo* H_0*; distinguir entre log-precios* $I(1)$ *y log-retornos* $I(0)$*.*

(a) No estacionariedad de la caminata aleatoria.

Sea $Y_t = Y_{t-1} + \varepsilon_t$ con $Y_0 = 0$. Por iteración: $Y_t = \sum_{i=1}^{t} \varepsilon_i$.

$$\mathrm{Var}(Y_t) = \sum_{i=1}^{t} \mathrm{Var}(\varepsilon_i) = t\,\sigma^2.$$

La varianza crece con t: la condición (i) de estacionariedad débil falla. Para $s \le t$:

$$\mathrm{Cov}(Y_t, Y_s) = \mathrm{Cov}\left(\sum_{i=1}^{t} \varepsilon_i, \sum_{j=1}^{s} \varepsilon_j\right) = \sum_{i=1}^{s} \sigma^2 = s\,\sigma^2 = \min(s,t)\,\sigma^2.$$

La covarianza depende de los tiempos absolutos, no solo del rezago $|t-s|$, lo que confirma la no estacionariedad.

_____ **Resultado final.** $\mathrm{Var}(Y_t) = t\,\sigma^2$; $\mathrm{Cov}(Y_t, Y_s) = \min(s,t)\,\sigma^2$. La caminata aleatoria no es estacionaria.

(b) $\Delta Y_t = \varepsilon_t$.

$$\Delta Y_t = Y_t - Y_{t-1} = (Y_{t-1} + \varepsilon_t) - Y_{t-1} = \varepsilon_t.$$

La primera diferencia de una caminata aleatoria es ruido blanco: un proceso $I(1)$ se vuelve $I(0)$ tras una diferencia.

(c) Por qué el estadístico ADF no sigue una distribución t clásica bajo H_0.

La regresión ADF es $\Delta Y_t = \mu + \delta Y_{t-1} + \sum_{j=1}^{k} \psi_j \Delta Y_{t-j} + \varepsilon_t$. Bajo $H_0 : \delta = 0$, el proceso Y_t es $I(1)$, de modo que Y_{t-1} no es estacionario: su varianza crece con T y, normalizado de forma estándar, converge a un funcional del movimiento browniano estándar (proceso de Wiener). La teoría clásica del estadístico t requiere que el regresor sea estacionario y satisfaga condiciones de momentos finitos uniformes; ninguna de esas condiciones se cumple aquí. Por ello, la distribución límite del estadístico $\hat{\delta}/\mathrm{SE}(\hat{\delta})$ es no estándar y requiere tablas críticas de Dickey–Fuller o MacKinnon.

(d) Log-precios $I(1)$ vs. log-retornos $I(0)$.

Si $p_t = \log P_t$, en finanzas se observa empíricamente que p_t sigue aproximadamente una caminata aleatoria con deriva: es $I(1)$, no estacionario en niveles. Los log-retornos

$$r_t = \Delta p_t = p_t - p_{t-1} = \log P_t - \log P_{t-1}$$

son la primera diferencia: generalmente $I(0)$, con media y varianza estables y dependencia serial débil en la media. La implicación es directa: modelar p_t requiere diferenciación (ARIMA); modelar r_t permite ARMA estacionario para la media y extensiones GARCH para la varianza condicional. Los pronósticos de p_t implican acumulación de cambios, con incertidumbre creciente en el horizonte.

Resultado final. Los log-precios son $I(1)$ y requieren diferenciación; los log-retornos son $I(0)$ y permiten modelado estacionario directo.

2. Modelos ARIMA(p, d, q)

Proceso ARIMA(p, d, q). $\Phi(B)(1-B)^d Y_t = \Theta(B)\varepsilon_t$, donde d es el orden de diferenciación.

Criterios de información.

$$\text{AIC} = -2\log\hat{L} + 2k, \qquad \text{BIC} = -2\log\hat{L} + k\log n,$$

donde $\hat{L}$ es la verosimilitud maximizada, k el número de parámetros y n el tamaño de muestra. BIC penaliza más la complejidad cuando $n > 7$.

Procedimiento de Box–Jenkins. (i) Identificación: graficar Y_t, ACF, PACF; aplicar diferencias si es necesario. (ii) Estimación: MV o mínimos cuadrados condicionales. (iii) Diagnóstico: verificar que los residuos sean ruido blanco.

Prueba de Ljung–Box. $Q = n(n+2)\sum_{k=1}^{h}\hat{\rho}_k^2/(n-k) \sim \chi^2(h-p-q)$ bajo H_0, con $h = \min(10, n/5)$.

Cointegración. Dos series $I(1)$ son cointegradas si existe β tal que $Z_t = Y_t - \beta X_t$ es $I(0)$.

Ejercicio 2.1 · Identificación, estimación y diagnóstico

Se solicita: *Identificar el orden del modelo para cuatro patrones hipotéticos de ACF/PACF; explicar AIC y BIC; describir Box–Jenkins en tres etapas; enunciar la prueba de Ljung–Box.*

(a) Identificación de modelos.

(i) *ACF decae exponencialmente; PACF se corta en el rezago 2.* — Patrón de **AR(2)**: la PACF corta en $p = 2$ y la ACF decae.

(ii) *ACF se corta en el rezago 1; PACF decae exponencialmente.* — Patrón de **MA(1)**: la ACF corta en $q = 1$ y la PACF decae.

(iii) *Ambas ACF y PACF decaen sin cortarse abruptamente.* — Patrón de **ARMA**(p, q) con $p > 0$, $q > 0$; ninguna de las dos presenta un corte limpio.

(iv) *ACF con pico significativo en el rezago 1 y aproximadamente cero después.* — Nuevamente **MA(1)**: la dependencia se agota en un solo rezago.

(b) AIC y BIC.

Ambos criterios equilibran bondad de ajuste y parsimonia. La penalización del AIC es $2k$, mientras que la del BIC es $k\log n$. Como $\log n > 2$ para $n > e^2 \approx 7.39$, el BIC penaliza más la complejidad en la práctica estadística habitual ($n > 7$). El AIC tiende a seleccionar modelos con mejor capacidad predictiva aunque algo más complejos; el BIC favorece parsimonia.

(c) Procedimiento de Box–Jenkins.

1. *Identificación.* Se grafican la serie, su ACF y su PACF; si hay raíz unitaria o estacionalidad, se aplican las diferencias necesarias. Se proponen órdenes candidatos.
2. *Estimación.* Se estiman los parámetros del modelo seleccionado por máxima verosimilitud o mínimos cuadrados condicionales, comparando candidatos con AIC/BIC.
3. *Diagnóstico.* Se verifican los residuos: ACF/PACF de residuos, gráfica temporal, histograma/QQ-plot y prueba de Ljung–Box. Si los residuos no son ruido blanco, se regresa a la etapa (i).

(d) Prueba de Ljung–Box.

Con $h = \min(10, n/5)$ rezagos, el estadístico

$$Q = n(n+2)\sum_{k=1}^{h} \frac{\hat{\rho}_k^2}{n-k}$$

sigue aproximadamente $\chi^2(h-p-q)$ bajo H_0 (residuos $\sim$ ruido blanco). Un p-valor grande indica que no se rechaza H_0: los residuos son compatibles con ruido blanco. Un p-valor pequeño revela dependencia serial no capturada y exige revisión del modelo.

Ejercicio 2.2 · ARIMA$(1,1,1)$ para log-precios de una acción

Se solicita: *Mostrar que el modelo se convierte en $ARMA(1,1)$ para retornos; calcular el pronóstico $\hat{r}_{T+1|T}$; construir intervalo de predicción al 95% para r_{T+1} y traducirlo a P_{T+1}; evaluar si el modelo captura asimetría en volatilidad.*

(a) Reducción a ARMA(1,1).

Sea $r_t = \Delta y_t = (1-B)y_t$. El modelo ARIMA$(1,1,1)$ es $(1-\phi_1 B)(1-B)y_t = (1+\theta_1 B)\varepsilon_t$, que equivale a $(1-\phi_1 B)r_t = (1+\theta_1 B)\varepsilon_t$, es decir:

$$\boxed{r_t = \phi_1 r_{t-1} + \varepsilon_t + \theta_1 \varepsilon_{t-1}.}$$

(b) Pronóstico $\hat{r}_{T+1|T}$ con $\hat{\phi}_1 = 0.15$, $\hat{\theta}_1 = -0.08$.

$$\hat{r}_{T+1|T} = \hat{\phi}_1 r_T + \hat{\phi}_1\hat{\theta}_1\hat{\varepsilon}_{T-1} + \hat{\theta}_1\hat{\varepsilon}_T = 0.15\, r_T + (0.15)(-0.08)\,\hat{\varepsilon}_{T-1} + (-0.08)\,\hat{\varepsilon}_T.$$

$$\boxed{\hat{r}_{T+1|T} = 0.15\, r_T - 0.012\,\hat{\varepsilon}_{T-1} - 0.08\,\hat{\varepsilon}_T.}$$

(c) Intervalo de predicción al 95% y traducción a P_{T+1}.

Para el retorno:

$$\mathrm{IC}_{95\%}(r_{T+1}) = \hat{r}_{T+1|T} \pm 1.96\,\hat{\sigma}.$$

Como $P_{T+1} = P_T\, e^{r_{T+1}}$, si $r_{T+1} \in [L, U]$ entonces $P_{T+1} \in [P_T e^L,\, P_T e^U]$:

$$\mathrm{IC}_{95\%}(P_{T+1}) = \left[P_T\, e^{\hat{r}_{T+1|T} - 1.96\hat{\sigma}},\; P_T\, e^{\hat{r}_{T+1|T} + 1.96\hat{\sigma}}\right].$$

(d) Captura de asimetría en volatilidad.

No. Un ARIMA$(1,1,1)$ modela únicamente la media condicional con varianza constante σ^2. La asimetría de volatilidad —por la cual choques negativos generan mayor volatilidad futura que choques positivos de igual magnitud— es un fenómeno de la *varianza condicional*. Para capturarlo se requiere un modelo tipo EGARCH o GJR-GARCH que incorpore la asimetría en la ecuación de varianza.

Ejercicio 2.3 · Pronóstico con ARIMA y horizonte múltiple

Se solicita: *Para el ARIMA$(2,1,0)$ dado con $\phi_1 = 0.5$, $\phi_2 = -0.2$, $\sigma^2 = 1$: definir $W_t = \Delta Y_t$; calcular $\hat{W}_{T+1|T}$ y $\hat{W}_{T+2|T}$; obtener ψ_0, ψ_1, ψ_2 y el ECM; construir intervalos al 95% y traducirlos a Y.*

(a) Definición de W_t y AR(2) resultante.

$W_t = \Delta Y_t = (1-B)Y_t$. El modelo se convierte en:

$$\boxed{W_t = 0.5\,W_{t-1} - 0.2\,W_{t-2} + \varepsilon_t.}$$

(b) Pronósticos a uno y dos pasos. Con $Y_T = 100$, $W_T = 1.2$, $W_{T-1} = 0.8$.

$$\hat{W}_{T+1|T} = 0.5(1.2) - 0.2(0.8) = 0.60 - 0.16 = \mathbf{0.44}.$$

$$\hat{W}_{T+2|T} = 0.5\,\hat{W}_{T+1|T} - 0.2\,W_T = 0.5(0.44) - 0.2(1.2) = 0.22 - 0.24 = -\mathbf{0.02}.$$

(c) Coeficientes MA y ECM.

$\psi_0 = 1, \quad \psi_1 = \phi_1 = 0.5, \quad \psi_2 = \phi_1\psi_1 + \phi_2\psi_0 = 0.5(0.5) - 0.2(1) = 0.05.$

$$\mathrm{MSE}_1 = \sigma^2\psi_0^2 = \mathbf{1}, \qquad \mathrm{MSE}_2 = \sigma^2(\psi_0^2 + \psi_1^2) = 1 + 0.25 = \mathbf{1.25}.$$

(d) Intervalos de predicción al 95% para W e Y.

Para W_{T+1}: $\hat{W}_{T+1|T} \pm 1.96\sqrt{1} = 0.44 \pm 1.96 \;\Rightarrow\; [-1.52,\ 2.40]$.

Para W_{T+2}: $-0.02 \pm 1.96\sqrt{1.25} = -0.02 \pm 2.19 \;\Rightarrow\; [-2.21,\ 2.17]$.

Traducción a niveles: $Y_{T+h} = Y_T + W_{T+1} + \cdots + W_{T+h}$.

- $\hat{Y}_{T+1|T} = 100.44$; $\mathrm{IC}_{95\%}(Y_{T+1}) = [98.48,\ 102.40]$.
- $\hat{Y}_{T+2|T} = 100.42$; El error acumulado es $e = 1.5\,\varepsilon_{T+1} + \varepsilon_{T+2}$, $\mathrm{Var} = 3.25$, $\mathrm{sd} \approx 1.803$; $\mathrm{IC}_{95\%}(Y_{T+2}) \approx [96.89,\ 103.95]$.

Ejercicio 2.4 · Cointegración y spreads estadísticos

Se solicita: *Enunciar el teorema de Granger e interpretar el término de corrección de error; explicar la estimación de β y la prueba de Engle–Granger; calcular media, varianza y vida media del spread AR(1); determinar cuándo es rentable el arbitraje con $\phi = 0.95$.*

(a) Teorema de representación de Granger.

Si Y_t y X_t son $I(1)$ y cointegradas, existe representación de corrección de error:

$$\Delta Y_t = \alpha(Y_{t-1} - \beta X_{t-1}) + \sum_j \gamma_j \Delta Y_{t-j} + \sum_j \delta_j \Delta X_{t-j} + \varepsilon_t.$$

El término $\alpha(Y_{t-1} - \beta X_{t-1})$ es la corrección de error: mide la desviación del equilibrio de largo plazo $Y = \beta X$ en el periodo anterior. Si $Y_{t-1} > \beta X_{t-1}$ y $\alpha < 0$, la corrección empuja a ΔY_t a la baja, restaurando el equilibrio. $|\alpha|$ indica la velocidad de ajuste.

(b) Estimación de β y prueba de Engle–Granger.

Etapa 1. Estimar por MCO la regresión $Y_t = \alpha + \beta X_t + u_t$; el estimador $\hat{\beta}$ es superconsistente. El spread es $\hat{Z}_t = Y_t - \hat{\beta} X_t$.

Etapa 2. Aplicar la prueba ADF sobre $\hat{Z}_t$. H_0: $\hat{Z}_t$ tiene raíz unitaria (no cointegración); H_1: $\hat{Z}_t$ es $I(0)$ (cointegración). Si se rechaza H_0, el spread es estacionario y explotable estadísticamente en pairs trading.

(c) Spread AR(1): $Z_t = \mu + \phi Z_{t-1} + \varepsilon_t$, $|\phi| < 1$.

$$\mathbb{E}[Z_t] = \frac{\mu}{1-\phi}, \qquad \mathrm{Var}(Z_t) = \frac{\sigma^2}{1-\phi^2}, \qquad h_{1/2} = \frac{\ln(0.5)}{\ln|\phi|} \text{ (vida media de reversión).}$$

(d) Con $\phi = 0.95$, $\mu = 0$, $\sigma = 0.01$.

$$\mathbb{E}[Z_t] = 0, \qquad \mathrm{Var}(Z_t) = \frac{0.0001}{1-0.9025} = \frac{0.0001}{0.0975} \approx 0.001026, \qquad \mathrm{sd}(Z_t) \approx 0.0320.$$

$$h_{1/2} = \frac{\ln 0.5}{\ln 0.95} = \frac{-0.6931}{-0.05129} \approx 13.5 \text{ semanas.}$$

El spread revierte, pero lentamente. La posición de arbitraje es rentable cuando $|Z_t - \mathbb{E}[Z_t]|$ supera varios múltiplos de $\mathrm{sd}(Z_t)$, típicamente $\geq 2\sigma_Z \approx 0.064$, siempre que la cointegración siga vigente y los costos de transacción sean menores que el beneficio esperado de la reversión.

Resultado final. $\mathbb{E}[Z_t] = 0$; $\mathrm{sd}(Z_t) \approx 0.0320$; $h_{1/2} \approx 13.5$ periodos.

3. Modelos SARIMA y estacionalidad

Modelo SARIMA$(p,d,q)(P,D,Q)_s$.

$$\Phi_P(B^s)\,\phi_p(B)\,(1-B^s)^D(1-B)^d\,Y_t = \Theta_Q(B^s)\,\theta_q(B)\,\varepsilon_t,$$

donde s es el periodo estacional, $\phi_p(B) = 1-\phi_1 B - \cdots - \phi_p B^p$ y análogamente para los demás operadores.

Diferencia estacional. $\Delta_s Y_t = Y_t - Y_{t-s} = (1-B^s)Y_t$.

Patrones estacionales. Parte AR estacional Φ_P: PACF se corta en $s, 2s, \ldots, Ps$; ACF decae en múltiplos de s. Parte MA estacional Θ_Q: ACF se corta en $s, 2s, \ldots, Qs$; PACF decae.

Modelo de Airline (Box–Jenkins). SARIMA$(0,1,1)(0,1,1)_{12}$: $(1-B)(1-B^{12})Y_t = (1+\theta_1 B)(1+\Theta_1 B^{12})\varepsilon_t$.

Ejercicio 3.1 · SARIMA$(p,d,q)(P,D,Q)_s$: estructura y notación

Se solicita: *Escribir explícitamente el SARIMA$(1,1,1)(1,1,1)_{12}$ expandido; calcular $\Delta_{12}(\Delta_1 Y_t)$ en términos de rezagos; describir patrones ACF/PACF que sugieren diferenciación estacional; argumentar la combinación (d,D) apropiada para ventas mensuales.*

(a) Expansión del SARIMA$(1,1,1)(1,1,1)_{12}$.

La forma compacta es $(1-\Phi_1 B^{12})(1-\phi_1 B)(1-B^{12})(1-B)Y_t = (1+\Theta_1 B^{12})(1+\theta_1 B)\varepsilon_t$.

Usando $(1-B^{12})(1-B) = 1-B-B^{12}+B^{13}$ y $(1-\phi_1 B)(1-\Phi_1 B^{12}) = 1-\phi_1 B-\Phi_1 B^{12}+\phi_1\Phi_1 B^{13}$, la forma expandida es:

$$\begin{aligned}\Big[1-(1+\phi_1)B+\phi_1 B^2-(1+\Phi_1)B^{12}+(1+\phi_1+\Phi_1+\phi_1\Phi_1)B^{13}\\ -\phi_1(1+\Phi_1)B^{14}+\Phi_1 B^{24}-\Phi_1(1+\phi_1)B^{25}+\phi_1\Phi_1 B^{26}\Big]Y_t\\ = \big(1+\theta_1 B+\Theta_1 B^{12}+\theta_1\Theta_1 B^{13}\big)\varepsilon_t.\end{aligned}$$

(b) $\Delta_{12}(\Delta_1 Y_t)$.

$(1-B^{12})(1-B) = 1-B-B^{12}+B^{13}$, de modo que:

$$\Delta_{12}(\Delta_1 Y_t) = Y_t - Y_{t-1} - Y_{t-12} + Y_{t-13}.$$

(c) Patrones que sugieren diferenciación estacional.

Antes de aplicar Δ_{12}: la ACF muestral presenta picos grandes y persistentes en $\rho(12)$, $\rho(24)$, $\rho(36), \ldots$ que no decaen rápidamente. Después de aplicar Δ_{12}: esos picos deben reducirse notablemente; si quedan, puede ser necesaria diferenciación estacional de orden $D=2$ (raro en práctica). La PACF ayuda a decidir si la parte estacional residual es AR o MA.

(d) Combinación (d, D) para ventas minoristas mensuales.

La elección más común y parsimoniosa es $d = 1$ (eliminar tendencia) y $D = 1$ (eliminar la componente estacional anual). Sobrediferenciar ($d = 2$ o $D = 2$) introduce ruido innecesario, incrementa la varianza del proceso diferenciado y complica la interpretación. El principio de parsimonia aconseja las menores diferencias que transformen la serie en aproximadamente estacionaria.

——— **Resultado final.** $(d, D) = (1, 1)$ es la combinación típica y razonable para ventas mensuales con tendencia y estacionalidad anuales.

Ejercicio 3.2 · SARIMA para ventas mensuales: modelo de Airline

Se solicita: *Expandir el lado izquierdo y derecho del modelo de Airline; calcular el pronóstico $\hat{V}_{61}$ con los datos dados; construir intervalos para V_{61} y V_{73} y explicar por qué crecen.*

(a) Expansión del lado izquierdo.

$(1 - B)(1 - B^{12}) = 1 - B - B^{12} + B^{13}$, luego:

$$(1 - B)(1 - B^{12})V_t = V_t - V_{t-1} - V_{t-12} + V_{t-13}.$$

(b) Ecuación completa del modelo.

El lado derecho: $(1 + \theta_1 B)(1 + \Theta_1 B^{12})\varepsilon_t = \varepsilon_t + \theta_1\varepsilon_{t-1} + \Theta_1\varepsilon_{t-12} + \theta_1\Theta_1\varepsilon_{t-13}$.

Despejando V_t:

$$V_t = V_{t-1} + V_{t-12} - V_{t-13} + \varepsilon_t + \theta_1\varepsilon_{t-1} + \Theta_1\varepsilon_{t-12} + \theta_1\Theta_1\varepsilon_{t-13}.$$

(c) Pronóstico $\hat{V}_{61}$.

Con $\hat{\theta}_1 = -0.4$, $\hat{\Theta}_1 = -0.6$, $V_{60} = 50$, $V_{49} = 45$, $V_{48} = 40$, $V_{47} = 35$, $\hat{\varepsilon}_{60} = 2$, $\hat{\varepsilon}_{48} = 1$, $\hat{\varepsilon}_{49} = 0$:

$$\begin{aligned}
\hat{V}_{61|60} &= V_{60} + V_{49} - V_{48} + \hat{\theta}_1\hat{\varepsilon}_{60} + \hat{\Theta}_1\hat{\varepsilon}_{49} + \hat{\theta}_1\hat{\Theta}_1\hat{\varepsilon}_{48} \\
&= 50 + 45 - 40 + (-0.4)(2) + (-0.6)(0) + (-0.4)(-0.6)(1) \\
&= 55 - 0.8 + 0 + 0.24 = \mathbf{54.44}.
\end{aligned}$$

(d) Intervalos y por qué crecen con el horizonte.

$\mathrm{IC}_{95\%}(V_{61}) = 54.44 \pm 1.96\,\hat{\sigma}$.

Para V_{73} (13 meses adelante), el error de pronóstico acumula más innovaciones no observadas: $\mathrm{Var}(e_{73}) = \hat{\sigma}^2 \sum_{j=0}^{12} \psi_j^2 > \hat{\sigma}^2$. Así, $\mathrm{IC}_{95\%}(V_{73}) = \hat{V}_{73} \pm 1.96\sqrt{\mathrm{Var}(e_{73})}$, con intervalo más ancho. El intervalo crece con el horizonte porque a mayor distancia del periodo de estimación, más innovaciones futuras desconocidas se acumulan en el error.

Ejercicio 3.3 · SARIMA para tasas de interés con ciclos trimestrales

Se solicita: *Proponer un SARIMA con $s = 13$ para CETES semanales; calcular pronóstico e intervalos al 80% y 95%; evaluar con ECMP vs. ARIMA no estacional; formular regla de trading.*

(a) Especificación del modelo.

Si la ACF muestra picos en rezagos 13, 26 y 39 con decaimiento gradual, la parte estacional es autorregresiva. Un modelo parsimonioso es:

$$\text{SARIMA}(1,1,0)(1,0,0)_{13},$$

con $d = 1$ para la posible no estacionariedad de la tasa, $p = 1$ para la dinámica de corto plazo y $P = 1$ para la dependencia estacional trimestral.

(b) Pronóstico e intervalos.

El pronóstico se obtiene iterativamente del modelo ajustado. Los intervalos son:

$$\text{IC}_{80\%} : \hat{Y}_{T+h|T} \pm 1.2816\sqrt{\text{MSE}_h}, \qquad \text{IC}_{95\%} : \hat{Y}_{T+h|T} \pm 1.96\sqrt{\text{MSE}_h},$$

donde $\text{MSE}_h = \hat{\sigma}^2 \sum_{j=0}^{h-1} \psi_j^2$ con coeficientes ψ_j de la representación MA(∞) del modelo ajustado.

(c) Evaluación con ECMP.

$$\text{ECMP} = \frac{1}{26}\sum_{h=1}^{26}(Y_{T+h} - \hat{Y}_{T+h|T})^2.$$

Se compara el SARIMA$(1,1,0)(1,0,0)_{13}$ con un ARIMA$(1,1,0)$ sin estacionalidad. Si la estructura trimestral es real, el SARIMA debe producir menor ECMP porque explota la dependencia sistemática en múltiplos de 13 semanas que el ARIMA no estacional ignora.

(d) Regla de decisión para trading de tasas.

La regla prudente consiste en operar únicamente cuando *todo* el intervalo de predicción respalda la dirección esperada:

- Vender futuros si incluso el límite inferior del intervalo de la tasa pronosticada supera la tasa actual.
- Comprar futuros si incluso el límite superior del intervalo queda por debajo del umbral relevante.
- No operar si el intervalo contiene escenarios contradictorios.

Los riesgos del modelo incluyen: error de especificación, cambios estructurales (e.g., modificación de política de Banxico), shocks no capturados y subestimación de la incertidumbre.

Ejercicio 3.4 · Descomposición STL y limpieza de estacionalidad

Se solicita: *Explicar las ventajas de STL frente a la descomposición clásica y X-12-ARIMA; calcular la serie desestacionalizada dada; explicar la mejora de STL+ARIMA para commodities; interpretar el indicador de fuerza estacional FS.*

(a) Ventajas de STL.

STL (Seasonal and Trend decomposition using Loess) descompone $Y_t = T_t + S_t + R_t$. Sus ventajas frente a la descomposición clásica y X-12-ARIMA son: (i) *robustez ante atípicos* mediante esquemas de ponderación robusta; (ii) *estacionalidad variable en el tiempo*, a diferencia de la descomposición clásica rígida; (iii) *flexibilidad* del ancho de ventana Loess; (iv) *no requiere estructura paramétrica ARIMA* para extraer la componente estacional.

(b) Serie desestacionalizada.

Con $T_t = 2 + 0.1t$ y $S_t = 3\sin(2\pi t/12)$:

$$Y_t^{des} = Y_t - S_t = T_t + R_t = 2 + 0.1t + R_t.$$

El ARIMA se ajusta sobre Y_t^{des}, que captura tendencia y ruido, no la componente estacional ya removida.

(c) STL+ARIMA para commodities.

En gas natural con estacionalidad invernal, un ARIMA directo sobre la serie bruta debe capturar simultáneamente tendencia, estacionalidad y dinámica serial, lo que puede forzar especificaciones poco parsimoniosas. Con STL+ARIMA: STL extrae limpiamente la componente estacional (posiblemente variable en el tiempo) y el ARIMA modela la dinámica restante de Y_t^{des}. El resultado suele ser: mayor parsimonia, parámetros más estables e intervalos de predicción mejor calibrados.

(d) Indicador de fuerza estacional.

$$FS = \max\left\{0,\ 1 - \frac{\mathrm{Var}(R_t)}{\mathrm{Var}(S_t + R_t)}\right\}.$$

- $FS \approx 0$: la varianza del residuo R_t es casi tan grande como la de $S_t + R_t$, lo que indica que la componente estacional explica muy poco. Estacionalidad débil o nula.
- $FS \approx 1$: $\mathrm{Var}(R_t) \ll \mathrm{Var}(S_t + R_t)$, de modo que la estacionalidad domina la variabilidad no tendencial. Estacionalidad fuerte y sistemática.

4. Modelos SARIMAX con variables exógenas

Modelo ARIMAX(p, d, q). $\phi_p(B)(1-B)^d Y_t = \boldsymbol{\beta}^\top \mathbf{x}_t + \theta_q(B)\varepsilon_t$, donde $\mathbf{x}_t \in \mathbb{R}^k$ son variables exógenas observadas en t.

Diferencia con regresión clásica. En ARIMAX, $u_t = \theta_q(B)\varepsilon_t$ es ARMA, no i.i.d. MCO ignorando la correlación produce estimadores ineficientes e inferencia inválida.

Estimación. Por máxima verosimilitud condicional.

SARIMAX. $\Phi_P(B^s)\phi_p(B)(1-B^s)^D(1-B)^d Y_t = \boldsymbol{\beta}^\top \mathbf{x}_t + \Theta_Q(B^s)\theta_q(B)\varepsilon_t$.

FIV. Factor de Inflación de la Varianza: $\text{FIV}_j = 1/(1-R_j^2)$; problemático si FIV > 10.

Ejercicio 4.1 · ARIMAX: incorporación de variables exógenas

Se solicita: *Explicar la diferencia entre ARIMAX y regresión clásica con errores correlacionados; proponer un ARIMAX$(1,1,0)$ para el tipo de cambio; derivar condiciones de estacionariedad; comparar AIC y BIC para seleccionar si incluir la variable exógena.*

(a) ARIMAX vs. regresión clásica.

En la regresión clásica $Y_t = \boldsymbol{\beta}^\top \mathbf{x}_t + u_t$ se asume u_t i.i.d. En ARIMAX, $u_t = \theta(B)\varepsilon_t$ sigue una estructura ARMA. Si se usa MCO ignorando esa autocorrelación: (i) los estimadores de $\boldsymbol{\beta}$ pueden seguir siendo insesgados, pero dejan de ser eficientes; (ii) los errores estándar calculados clásicamente son incorrectos; (iii) la inferencia t y F es inválida; (iv) se desaprovecha la dinámica serial de los errores, empeorando los pronósticos.

(b) ARIMAX$(1,1,0)$ para el tipo de cambio MXN/USD.

Sea Y_t el log del tipo de cambio MXN/USD y x_t el diferencial de tasas México–EE.UU.:

$$(1-\phi_1 B)(1-B)Y_t = \beta\, x_t + \varepsilon_t, \qquad \beta < 0 \text{ esperado.}$$

El signo negativo refleja que un mayor diferencial a favor de México aprecia al peso, haciendo bajar el tipo de cambio (pesos por dólar).

(c) Condiciones de estacionariedad del ARMAX.

Se requiere que las raíces del polinomio AR satisfagan $|\Phi(z) = 0| \Rightarrow |z| > 1$. Además, el comportamiento de $\mathbf{x}_t$ importa: si $\mathbf{x}_t$ es $I(0)$, entra directamente; si es $I(1)$, el modelo puede heredar no estacionariedad salvo que se diferencie de forma compatible o exista una relación de cointegración entre Y_t y $\mathbf{x}_t$.

(d) Selección AIC/BIC.

Se estiman el ARIMA puro y el ARIMAX y se comparan AIC y BIC. Si el ARIMAX produce AIC menor, el ajuste mejoró lo suficiente para justificar el parámetro extra desde el punto de vista predictivo. Si además el BIC baja, la mejora supera la penalización más estricta. Para objetivos de pronóstico, el AIC es más informativo; para parsimonia e interpretación, el BIC.

Ejercicio 4.2 · SARIMAX para demanda de energía eléctrica

Se solicita: *Justificar los órdenes de diferenciación y estacionalidad; enunciar la construcción de la log-verosimilitud; calcular el pronóstico horario; calcular el ECMP y comparar con el naïve estacional.*

(a) Justificación de diferenciación y estacionalidad.

El modelo propuesto es $\phi(B)(1-B^{24})(1-B)D_t = \beta_0 + \beta_1 \mathrm{Temp}_t + \theta(B)\varepsilon_t$.

$(1-B)$ elimina tendencia o persistencia de baja frecuencia; $(1-B^{24})$ elimina la estacionalidad diaria (la demanda a una hora dada se parece a la de la misma hora del día anterior). La estacionalidad semanal ($s_2 = 168$) requeriría extensión adicional o el uso de variables dummies o series de Fourier.

Sobre el signo de β_1: en verano domina el aire acondicionado ($\beta_1 > 0$); en invierno puede dominar la calefacción eléctrica ($\beta_1 < 0$). Con un único coeficiente lineal, el signo refleja el efecto promedio anual neto.

(b) Log-verosimilitud condicional.

Bajo normalidad condicional, $y_t \mid \mathcal{F}_{t-1} \sim N(\hat{y}_{t|t-1}, \sigma_t^2)$. La log-verosimilitud es:

$$\ell(\boldsymbol{\theta}) = \sum_{t=1}^{T} \log p(y_t \mid y_{t-1}, \ldots, y_1, \mathbf{x}_t; \boldsymbol{\theta}) = -\frac{T}{2}\log(2\pi) - \frac{1}{2}\sum_{t=1}^{T}\left[\log \sigma_t^2 + \frac{(y_t - \hat{y}_{t|t-1})^2}{\sigma_t^2}\right].$$

(c) Pronóstico horario.

Se itera recursivamente el modelo con $\mathbb{E}[\varepsilon_{T+h}] = 0$:

$$\hat{D}_{T+h|T}: \quad \phi(B)(1-B^{24})(1-B)\hat{D}_{T+h} = \beta_0 + \beta_1 \mathrm{Temp}_{T+h|T}, \quad h = 1, \ldots, 24.$$

Los valores futuros de temperatura se tratan como conocidos (pronóstico meteorológico externo) o se pronostican con un modelo separado, lo cual agrega incertidumbre adicional.

(d) ECMP y comparación con el naïve estacional.

$$\mathrm{ECMP} = \frac{1}{72}\sum_{h=1}^{72}(D_{T+h} - \hat{D}_{T+h|T})^2.$$

El naïve estacional predice $\hat{D}_{T+h}^{\text{naïve}} = D_{T+h-168}$ (mismo valor hace siete días). Si $\mathrm{ECMP}_{\mathrm{SARIMAX}} < \mathrm{ECMP}_{\text{naïve}}$, el modelo estructurado mejora. De lo contrario, el naïve es competitivo y el modelo puede ser innecesariamente complejo.

Ejercicio 4.3 · SARIMAX para ventas con efectos de calendario

Se solicita: *Interpretar β_1 y β_2; explicar la transformación $\log V_t$; evaluar multicolinealidad con FIV; construir el pronóstico e intervalos a 12 semanas con petróleo pronosticado.*

El modelo es $(1-B)(1-B^{52})\log V_t = \beta_1 F_t + \beta_2 \Delta \log P_t + (1+\theta B)(1+\Theta B^{52})\varepsilon_t$.

(a) Interpretación de β_1 y β_2.

β_1 mide el efecto discreto de un día festivo ($F_t = 1$) sobre la variación semanal-anual-diferenciada del log de ventas; aproximadamente, $100\beta_1\%$ de cambio porcentual en ventas. β_2 es la elasticidad de corto plazo de ventas respecto al cambio porcentual del petróleo: si P_t sube 1%, las ventas ajustadas varían en $\beta_2\%$.

(b) Por qué usar $\log V_t$.

(i) Estabiliza la varianza: en series de ventas, la dispersión suele crecer con el nivel; los logaritmos homogenizan la varianza. (ii) Interpretación porcentual: $\Delta \log V_t \approx \%\Delta V_t$, lo que facilita la lectura económica de los parámetros. (iii) Los errores del modelo logarítmico suelen aproximarse mejor a la normalidad, mejorando la validez de la inferencia.

(c) Multicolinealidad con FIV.

$\mathrm{FIV}_j = 1/(1 - R_j^2)$, donde R_j^2 proviene de regredir x_j sobre los demás regresores. Se evalúa regresando F_t sobre $\Delta \log P_t$ y viceversa. Si $\mathrm{FIV} > 10$, la multicolinealidad es problemática: infla errores estándar, hace inestables los coeficientes e invalida la interpretación marginal. Soluciones: eliminar el regresor redundante, redefinir variables o aplicar regularización.

(d) Pronóstico a 12 semanas con P_{T+h} pronosticado.

El pronóstico puntual usa F_{T+h} conocido (calendario) y $\hat{P}_{T+h}$ pronosticado por un AR(1) separado. La varianza total del error se descompone:

$$\mathrm{Var}(e_{\mathrm{total},h}) \approx \mathrm{Var}(e_{\mathrm{SARIMAX},h}) + \beta_2^2\ \mathrm{Var}(\Delta \log \hat{P}_{T+h}).$$

El intervalo al 95% en escala logarítmica es $\widehat{\log V}_{T+h} \pm 1.96\sqrt{\mathrm{Var}(e_{\mathrm{SARIMAX},h}) + \beta_2^2\,\mathrm{Var}(e_{P,h})}$, que se retransforma exponencialmente para obtener el intervalo en niveles de ventas.

5. Simulación, Yule-Walker e interpretación gráfica

Ecuaciones de Yule-Walker para AR(p). $\gamma(k) = \sum_{j=1}^{p} \phi_j \gamma(k-j)$ para $k = 1, \ldots, p$. En forma matricial: $\boldsymbol{\Gamma}_p \boldsymbol{\phi} = \boldsymbol{\gamma}_p$.

Estimación Yule-Walker. $\hat{\boldsymbol{\phi}} = \hat{\boldsymbol{\Gamma}}_p^{-1} \hat{\boldsymbol{\gamma}}_p$. Consistente y asintóticamente normal.

Representación MA(∞). $Y_t = \sum_{j=0}^{\infty} \psi_j \varepsilon_{t-j}$: $\psi_0 = 1$, $\psi_j = \sum_{k=1}^{\min(j,p)} \phi_k \psi_{j-k}$.

ECM de predicción. $\mathrm{MSE}_h = \sigma^2 \sum_{j=0}^{h-1} \psi_j^2$.

Bandas de significancia. Bajo H_0: ruido blanco, $\hat{\rho}(k) \approx N(0, 1/T)$. Banda al 95%: $\pm 1.96/\sqrt{T}$.

Bootstrap paramétrico. (1) Estimar el modelo; (2) simular B trayectorias muestreando $\varepsilon^{(b)} \sim N(0, \hat{\sigma}^2)$; (3) tomar percentiles 2.5% y 97.5%.

Ejercicio 5.1 · Ecuaciones de Yule-Walker y estimación AR

Se solicita: *Derivar Yule-Walker para AR(1); resolver el sistema para AR(2) con $\phi_1 = 0.6$, $\phi_2 = -0.2$; explicar consistencia y uso de Cholesky; aplicar Yule-Walker con $p = 1$ y $p = 2$ a los datos del IPC y construir IC al 95% para $\rho(1)$.*

(a) Yule-Walker para AR(1).

Multiplicando $Y_t = \phi_1 Y_{t-1} + \varepsilon_t$ por Y_{t-1} y tomando esperanza: $\gamma(1) = \phi_1 \gamma(0)$, luego $\phi_1 = \gamma(1)/\gamma(0) = \rho(1)$.

Multiplicando por Y_t: $\gamma(0) = \phi_1 \gamma(1) + \sigma^2 = \phi_1^2 \gamma(0) + \sigma^2$, de donde $\sigma^2 = \gamma(0)(1 - \phi_1^2)$.

$$\boxed{\phi_1 = \rho(1), \qquad \sigma^2 = \gamma(0)(1 - \phi_1^2).}$$

(b) AR(2) con $\phi_1 = 0.6$, $\phi_2 = -0.2$.

Sistema de Yule-Walker:

$$\gamma(1) = \phi_1 \gamma(0) + \phi_2 \gamma(1) \;\Rightarrow\; 1.2\gamma(1) = 0.6\gamma(0) \;\Rightarrow\; \gamma(1) = 0.5\,\gamma(0).$$

$$\gamma(2) = \phi_1 \gamma(1) + \phi_2 \gamma(0) = 0.3\gamma(0) - 0.2\gamma(0) = 0.1\,\gamma(0).$$

$$\gamma(0) = \phi_1 \gamma(1) + \phi_2 \gamma(2) + \sigma^2 = 0.3\gamma(0) - 0.02\gamma(0) + \sigma^2 = 0.28\gamma(0) + \sigma^2.$$

$$0.72\,\gamma(0) = \sigma^2 \;\Rightarrow\; \boxed{\gamma(0) = \frac{25\sigma^2}{18}, \quad \gamma(1) = \frac{25\sigma^2}{36}, \quad \gamma(2) = \frac{5\sigma^2}{36}.}$$

(c) Consistencia y descomposición de Cholesky.

El estimador Yule-Walker es consistente porque, bajo estacionariedad y ergodicidad, las autocovarianzas muestrales $\hat{\gamma}(k) = T^{-1} \sum_t Y_t Y_{t-k}$ convergen en probabilidad a las poblacionales, y la inversión matricial es continua. La matriz de Toeplitz $\hat{\boldsymbol{\Gamma}}_p$ es simétrica y definida positiva; la descomposición de Cholesky $\hat{\boldsymbol{\Gamma}}_p = \mathbf{L}\mathbf{L}^\top$ permite resolver el sistema en dos pasos triangulares ($\mathbf{L}\mathbf{z} = \hat{\boldsymbol{\gamma}}_p$; $\mathbf{L}^\top \hat{\boldsymbol{\phi}} = \mathbf{z}$), lo que es numéricamente estable y más eficiente que invertir directamente.

(d) Aplicación con $T = 1000$, $\hat{\rho}(1) = 0.12$, $\hat{\rho}(2) = -0.04$.

Para $p = 1$: $\hat{\phi}_1 = \hat{\rho}(1) = 0.12$.

Para $p = 2$:

$$\hat{\phi}_2 = \frac{\hat{\rho}(2) - \hat{\rho}(1)^2}{1 - \hat{\rho}(1)^2} = \frac{-0.04 - 0.0144}{0.9856} \approx -0.0552.$$

$$\hat{\phi}_1 = \hat{\rho}(1)(1 - \hat{\phi}_2) = 0.12(1.0552) \approx 0.1266.$$

IC al 95% para $\rho(1)$: Bajo H_0 (ruido blanco), $\hat{\rho}(k) \approx N(0, 1/T)$, luego $\mathrm{IC}_{95\%}(\rho(1)) = 0.12 \pm 1.96/\sqrt{1000} = 0.12 \pm 0.062 = [0.058,\ 0.182]$.

Como el intervalo no contiene 0, $\hat{\rho}(1) = 0.12$ es **estadísticamente significativo**.

Ejercicio 5.2 · Simulación de un AR(2) y diagnóstico gráfico

Se solicita: *Identificar el orden a partir de ACF/PACF; estimar $\hat{\phi}_1$, $\hat{\phi}_2$ con Yule-Walker y comparar con valores verdaderos; calcular las raíces complejas del polinomio AR e interpretar; calcular la varianza teórica $\gamma(0)$.*

(a) Identificación del orden.

El proceso simulado es $Y_t = 0.7Y_{t-1} - 0.3Y_{t-2} + \varepsilon_t$, un AR(2). La PACF debe mostrar dos rezagos significativos y luego cortar (en rezago 2). La ACF decae gradualmente con oscilaciones amortiguadas, consistente con raíces complejas. Los valores muestrales $\hat{\rho}(1) = 0.61$ y $\hat{\rho}(2) = 0.22$ con un patrón de decaimiento oscilante son coherentes con un AR(2).

(b) Estimación Yule-Walker.

$$\hat{\phi}_2 = \frac{0.22 - 0.61^2}{1 - 0.61^2} = \frac{0.22 - 0.3721}{0.6279} \approx -0.242.$$

$$\hat{\phi}_1 = 0.61(1 + 0.242) \approx 0.758.$$

Comparación con valores verdaderos $(\phi_1, \phi_2) = (0.7, -0.3)$: $\hat{\phi}_1 \approx 0.758$ (algo mayor) y $\hat{\phi}_2 \approx -0.242$ (algo menos negativo), diferencias debidas al error muestral con $T = 300$.

(c) Raíces complejas del polinomio AR.

$1 - 0.7z + 0.3z^2 = 0 \;\Rightarrow\; 0.3z^2 - 0.7z + 1 = 0$:

$$z = \frac{0.7 \pm \sqrt{0.49 - 1.2}}{0.6} = \frac{0.7 \pm \sqrt{-0.71}}{0.6} = \frac{0.7 \pm i\sqrt{0.71}}{0.6}.$$

$\sqrt{0.71} \approx 0.8426$, luego $z \approx 1.1667 \pm 1.4043i$, con módulo:

$$|z| = \sqrt{1.1667^2 + 1.4043^2} = \sqrt{1.3611 + 1.9721} \approx \sqrt{3.333} \approx 1.826 > 1.$$

Las raíces son complejas y fuera del círculo unitario: el proceso es estacionario. Las raíces complejas implican que la ACF teórica presenta *oscilaciones amortiguadas* con frecuencia proporcional al argumento de las raíces complejas.

(d) Varianza teórica $\gamma(0)$.

Con $\phi_1 = 0.7$, $\phi_2 = -0.3$, $\sigma^2 = 1$ y el sistema Yule-Walker: $\gamma(1) = \frac{0.7}{1.3}\gamma(0) \approx 0.5385\,\gamma(0)$; $\gamma(2) \approx 0.0769\,\gamma(0)$.

Sustituyendo en $\gamma(0) = \phi_1\gamma(1) + \phi_2\gamma(2) + \sigma^2$:

$$\gamma(0) = 0.35384\,\gamma(0) + 1 \;\Rightarrow\; 0.64616\,\gamma(0) = 1 \;\Rightarrow\; \boxed{\gamma(0) \approx 1.548.}$$

La varianza muestral de la simulación con $T = 300$ debería estar próxima a 1.548, con diferencias debidas únicamente a variabilidad muestral.

Ejercicio 5.3 · Tabla de rendimientos y ajuste ARIMA a log-retornos del IPC

Se solicita: *Interpretar la tabla de log-retornos del IPC por periodos; estimar $\hat{\phi}_1$ y $\hat{\sigma}^2$ por Yule-Walker para Jul-Dic 2020 y construir IC al 95%; evaluar si un ARIMA$(1,0,0)$ es apropiado para Ene-Jun 2020; comentar simulación vs. ACF teórica.*

(a) Interpretación de la tabla.

Periodo	Media	Des. Est.	Asim.	Curtosis	$\hat{\rho}(1)$	$\hat{\rho}(5)$
Ene-Jun 2020	-0.0008	0.0221	-0.87	6.23	0.08	-0.03
Jul-Dic 2020	0.0012	0.0148	-0.42	4.11	0.12	0.05
Ene-Jun 2022	-0.0003	0.0131	0.21	3.85	0.06	-0.02
Jul-Dic 2023	0.0009	0.0117	-0.18	3.44	0.09	0.01

Mayor volatilidad: Ene-Jun 2020 ($\sigma = 0.0221$), consistente con el choque de la pandemia. Mayor asimetría negativa: Ene-Jun 2020 (-0.87), reflejo de caídas abruptas y cola izquierda gruesa. Curtosis > 3 en todos los periodos (colas más pesadas que la normal), con el caso más extremo en Ene-Jun 2020 (curtosis 6.23), compatible con eventos de mercado extremos.

(b) Estimación Yule-Walker para Jul-Dic 2020.

$\hat{\phi}_1 = \hat{\rho}(1) = 0.12$. Con $\hat{\gamma}(0) = (0.0148)^2 = 0.00021904$:

$$\hat{\sigma}^2 = \hat{\gamma}(0)(1 - \hat{\phi}_1^2) = 0.00021904(1 - 0.0144) \approx 0.00021589.$$

IC al 95% para ϕ_1 con $T \approx 126$ observaciones semestrales diarias:

$$\hat{\phi}_1 \pm \frac{1.96}{\sqrt{126}} = 0.12 \pm 0.175 = [-0.055,\ 0.295].$$

El intervalo contiene cero: $\hat{\phi}_1$ no es estadísticamente significativo al 95%.

(c) ¿Es apropiado un ARIMA$(1,0,0)$ para Ene-Jun 2020?

Con $\hat{\rho}(1) = 0.08$, la dependencia en media es débil. El problema central es la *heteroscedasticidad condicional*: desviación estándar elevada (0.0221), curtosis $6.23 \gg 3$ y fuerte asimetría negativa son signos claros de clustering de volatilidad y colas pesadas. Un ARIMA$(1,0,0)$ modela solo la media condicional con varianza constante: es insuficiente. La extensión natural

es ARIMA$(1,0,0)$–EGARCH o GJR-GARCH para capturar la asimetría del efecto de apalancamiento.

(d) Simulación vs. ACF teórica.

La ACF teórica de un AR(1) con $\phi_1 = 0.12$ es $\rho(k) = 0.12^k$: cae extremadamente rápido ($\rho(1) = 0.12$, $\rho(2) = 0.0144$, $\rho(3) \approx 0.0017$). Con $T = 126$ observaciones, la banda de significancia es $\pm 1.96/\sqrt{126} \approx \pm 0.175$, de modo que prácticamente ningún rezago (ni el primero) es claramente significativo. Las discrepancias entre ACF muestral y teórica se deben a variabilidad aleatoria de la simulación, longitud reducida de la muestra y el ruido propio del proceso estocástico.

Ejercicio 5.4 · Simulación SARIMA y diagnóstico estacional

Se solicita: *Interpretar los picos de la ACF en rezagos 12, 24, 36; calcular la ACF teórica en $k = 1, 12, 13, 24$; proponer el orden SARIMA mediante Box-Jenkins; calcular el error Yule-Walker para Φ_1 y explicar el sesgo de muestra pequeña.*

(a) Interpretación de la ACF.

El modelo simulado es $(1 - \Phi_1 B^{12})Y_t = (1 + \theta_1 B)\varepsilon_t$, $\Phi_1 = 0.8$, $\theta_1 = -0.5$. Los picos en $k = 12, 24, 36$ indican dependencia estacional fuerte de periodo 12. El decaimiento progresivo $(0.72, 0.55, 0.41)$ es consecuencia de la parte AR estacional: en un AR estacional de orden 1, la autocorrelación en múltiplos del periodo decae aproximadamente como Φ_1^m, y como $\Phi_1 = 0.8$, los picos son altos pero disminuyen.

(b) ACF teórica en $k = 1, 12, 13, 24$.

Con $\Phi_1 = 0.8$, $\theta_1 = -0.5$, $\sigma^2 = 1$ y $\gamma(0) = \frac{1+\theta_1^2}{1-\Phi_1^2} = \frac{1.25}{0.36} \approx 3.4722$:

$$\rho(1) = \frac{\theta_1/(1-\Phi_1^2)}{\gamma(0)} = \frac{-0.5/0.36}{3.4722} \approx -0.40.$$

$$\rho(12) = \Phi_1 \cdot \frac{1+\theta_1^2}{1-\Phi_1^2}/\gamma(0) = \frac{0.8 \times 1.25}{3.4722 \times 0.36 \times (1+\theta_1^2)} \;\Rightarrow\; \rho(12) = 0.80.$$

$$\rho(13) = \theta_1\Phi_1/(\gamma(0)(1-\Phi_1^2)) \cdot (1+\theta_1^2)^{-1} \;\Rightarrow\; \rho(13) \approx -0.32.$$

$$\rho(24) = \Phi_1^2 \cdot (1+\theta_1^2)/(1-\Phi_1^2)/\gamma(0) \;\Rightarrow\; \rho(24) = 0.64.$$

Resultado final. $\rho(1) = -0.40$; $\rho(12) = 0.80$; $\rho(13) = -0.32$; $\rho(24) = 0.64$.

(c) Propuesta de orden SARIMA.

La ACF muestra: pico negativo en $k = 1$ (MA(1) no estacional) y picos decrecientes en $k = 12, 24, 36$ (AR estacional). No hay evidencia de raíz unitaria (picos estacionales no son extremadamente persistentes ni la serie en niveles parece no estacionaria). El orden sugerido es:

$$\text{SARIMA}(0,0,1)(1,0,0)_{12}, \quad d = 0,\ D = 0.$$

(d) Error Yule-Walker para Φ_1.

$\hat{\Phi}_1 = \hat{\rho}(12) = 0.72$ frente al valor verdadero $\Phi_1 = 0.8$. Error: $\hat{\Phi}_1 - \Phi_1 = 0.72 - 0.80 = -0.08$.

El sesgo hacia abajo en muestras pequeñas ($T = 120$) se debe a: (i) las autocorrelaciones muestrales en rezagos altos son ruidosas y en promedio algo subestimadas; (ii) la presencia del MA(1) no estacional introduce variabilidad adicional en la estimación; (iii) el sesgo general de estimadores de autocorrelación en muestras finitas tiende a comprimir las estimaciones hacia cero.

Ejercicio 5.5 · Tabla comparativa de modelos: pronóstico MXN/USD

Se solicita: *Interpretar la tabla comparativa (AIC, BIC, RMSE, MAE); explicar por qué la banda crece con el horizonte y calcular la amplitud al 95% en $h = 6$; calcular explícitamente $\hat{Y}_{T+1|T}$ y $\hat{Y}_{T+2|T}$; proponer cobertura cambiaria para importadora.*

(a) Interpretación de la tabla comparativa.

Modelo	AIC	BIC	RMSE	MAE	$\hat{\sigma}^2$	Pars.
ARIMA$(1,1,0)$	-48.2	-45.1	0.341	0.278	0.0118	1
ARIMA$(1,1,1)$	-51.7	-47.0	0.312	0.251	0.0103	2
SARIMA$(1,1,1)(1,0,1)_{12}$	-54.3	-47.8	0.298	0.239	0.0098	4

Según AIC y BIC, el mejor ajuste dentro de muestra es el SARIMA (AIC $= -54.3$, BIC $= -47.8$, ambos los más negativos). AIC y BIC *coinciden* en la elección. Fuera de muestra, también gana el SARIMA: menor RMSE (0.298) y menor MAE (0.239).

(b) Banda de confianza creciente con el horizonte.

La banda crece porque el error de pronóstico acumula innovaciones futuras desconocidas. En procesos integrados, la incertidumbre crece aún más por la acumulación de diferencias. La aproximación para ARIMA$(1,1,0)$ con $\hat{\sigma} = \sqrt{0.0118} \approx 0.1086$:

$$\text{Amplitud}_{h=6} = 2 \times 1.96 \times \hat{\sigma}\sqrt{6} = 2(1.96)(0.1086)(2.449) \approx \mathbf{1.04}.$$

(c) Cálculo explícito de $\hat{Y}_{T+1|T}$ y $\hat{Y}_{T+2|T}$.

Con $\hat{\phi}_1 = 0.3$, $\hat{\theta}_1 = -0.4$, $\Delta Y_T = 0.16$, $\hat{\varepsilon}_T = 0.05$:

$$\Delta\hat{Y}_{T+1|T} = \hat{\phi}_1 \Delta Y_T + \hat{\theta}_1 \hat{\varepsilon}_T = 0.3(0.16) + (-0.4)(0.05) = 0.048 - 0.020 = 0.028.$$

$$\hat{Y}_{T+1|T} = Y_T + 0.028.$$

$$\Delta\hat{Y}_{T+2|T} = \hat{\phi}_1 \cdot 0.028 = 0.3(0.028) = 0.0084.$$

$$\hat{Y}_{T+2|T} = Y_T + 0.028 + 0.0084 = Y_T + 0.0364.$$

(d) Cobertura cambiaria para importadora.

El SARIMA produce un intervalo $[L_h, U_h]$ para el tipo de cambio en $t + h = 3$ meses. Para una importadora que debe comprar dólares, el riesgo relevante es el alza del tipo de cambio. Por ello:

- Para presupuesto y cobertura prudente, se usa el **percentil 95%** (U_h), no el punto central.

- Un *forward* permite fijar hoy el precio y eliminar toda incertidumbre.
- Una *opción call* sobre USD (equivalente a put sobre MXN) paga prima pero preserva el beneficio si el tipo de cambio termina más favorable.

El punto central es el mejor estimador puntual, pero para cobertura conservadora la cola superior del intervalo es la referencia correcta.

Ejercicio 5.6 · Simulación de Monte Carlo para evaluación de pronósticos

Se solicita: *Demostrar que* $Y_{T+h} \mid Y_T = y_0 \sim N\left(\phi_1^h y_0,\, \sigma^2 \frac{1-\phi_1^{2h}}{1-\phi_1^2}\right)$*; completar la tabla de IC analíticos para* $h = 1, 5, 10, \infty$*; describir el algoritmo de Monte Carlo y comparar; interpretar el fan chart.*

(a) Distribución condicional del AR(1).

Por iteración, $Y_{T+h} = \phi_1^h Y_T + \sum_{j=0}^{h-1} \phi_1^j \varepsilon_{T+h-j}$. Como $Y_T = y_0$ es conocido:

$$\mathbb{E}[Y_{T+h} \mid Y_T = y_0] = \phi_1^h\, y_0.$$

$$\mathrm{Var}(Y_{T+h} \mid Y_T = y_0) = \sigma^2 \sum_{j=0}^{h-1} \phi_1^{2j} = \sigma^2 \cdot \frac{1-\phi_1^{2h}}{1-\phi_1^2}.$$

Al ser combinación lineal de normales:

$$\boxed{Y_{T+h} \mid Y_T = y_0 \;\sim\; N\left(\phi_1^h\, y_0,\; \sigma^2\, \frac{1-\phi_1^{2h}}{1-\phi_1^2}\right).}$$

(b) Tabla de IC analíticos al 95%, $y_0 = 2$, $\phi_1 = 0.6$, $\sigma = 1$.

h	$\mathbb{E}[Y_{T+h}]$	$\mathrm{Var}(Y_{T+h})$	LI 95%	LS 95%
1	1.2000	1.0000	−0.760	3.160
5	0.1555	1.5531	−2.287	2.598
10	0.0121	1.5624	−2.438	2.462
∞	0	1.5625	−2.450	2.450

La media converge a 0 y la varianza converge a $\sigma^2/(1-\phi_1^2) = 1/0.64 = 1.5625$.

(c) Algoritmo de Monte Carlo y comparación con el IC analítico.

1. Estimar $\hat{\phi}_1$ y $\hat{\sigma}^2$ del modelo ajustado; fijar $Y_T = y_0$.
2. Para cada réplica $b = 1, \ldots, B = 1000$: generar $\varepsilon_{T+1}^{(b)}, \ldots, \varepsilon_{T+h}^{(b)} \overset{iid}{\sim} N(0, \hat{\sigma}^2)$ y construir $Y_{T+j}^{(b)} = \hat{\phi}_1 Y_{T+j-1}^{(b)} + \varepsilon_{T+j}^{(b)}$.
3. Para cada horizonte h, el IC empírico es $[\text{percentil}_{2.5\%}\{Y_{T+h}^{(b)}\},\ \text{percentil}_{97.5\%}\{Y_{T+h}^{(b)}\}]$.

Con $B = 1000$, la diferencia típica entre el IC empírico y el analítico es del orden de $1/\sqrt{B} \approx 3\%$: pequeña pero no nula. Diferencias adicionales surgen si se usa $\hat{\phi}_1$ estimado en vez del valor verdadero.

(d) Interpretación del fan chart.

El abanico se abre al principio porque el error de pronóstico acumula innovaciones futuras no observadas. En un AR(1) estacionario ($|\phi_1| < 1$), esa apertura no crece indefinidamente:

- La media del abanico converge a $\mathbb{E}[Y_t] = 0$ (media incondicional del proceso).
- La varianza converge a $\sigma^2/(1-\phi_1^2)$: la incertidumbre se estabiliza en el nivel estacionario.
- Cuando $h \to \infty$: el pronóstico puntual pierde toda información de y_0 y el intervalo coincide con el intervalo de predicción del proceso en estado estacionario.

Resultado final. El abanico se abre por acumulación de error, recentra la media en el valor estacionario y estabiliza su amplitud en $\pm 1.96\,\sigma/\sqrt{1-\phi_1^2}$.